Universidad Politécnica Metropolitana del Estado de Hidalgo

Maestría en Inteligencia Artificial

Algoritmo Genético para Selección de Cartera de Proyectos

Materia: Algoritmos Evolutivos
Alumnos: Jessica Melani Romero Lora, Victor Manuel Santos Martínez
Profesor: Dr. Jaime Aguilar Ortiz
Link: https://github.com/VManuelSM/MIA_C4_AAEE_Corte_01_Actividad_03

1. Formulación del problema

Una empresa dispone de ‘d’ proyectos candidatos. Cada proyecto j requiere una inversión c□ y h□ horas-persona, y aporta un valor esperado v□. La decisión es binaria: x□ = 1 si el proyecto entra en la cartera, x□ = 0 si no. El problema se formula como:

$$\text{Maximizar } Z = \Sigma\square\ v\square \cdot x\square$$

sujeto a las restricciones de presupuesto, capacidad de horas, dependencias entre proyectos y exclusiones mutuas:

$$\Sigma\square\ c\square \cdot x\square \le B \quad \text{(presupuesto)}$$
$$\Sigma\square\ h\square \cdot x\square \le H \quad \text{(capacidad de horas)}$$
$$x\square \le x_i \quad \forall (i,j) \in \text{Dependencias}$$
$$x_a + x_b \le 1 \quad \forall (a,b) \in \text{Exclusiones}$$

Este es un problema de programación entera binaria (0-1 knapsack bidimensional con restricciones laterales). Para d = 50, el espacio tiene $2^{50} \approx 10^{15}$ soluciones posibles, lo que hace inviable la enumeración completa y justifica el uso de un algoritmo genético.

2. Arquitectura del algoritmo genético

El AG sigue la estructura de siete etapas propuesta por Aguilar Ortiz, eligiendo un método por etapa según la compatibilidad con la representación binaria y las restricciones del problema:

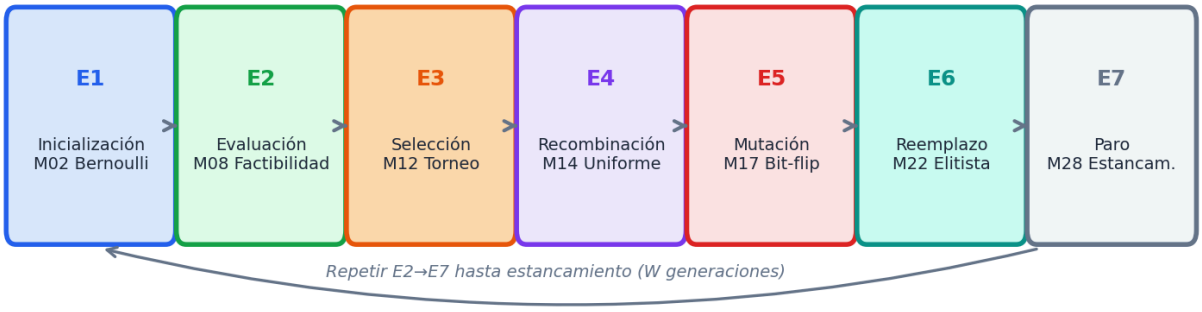


Figura 1. Pipeline de las siete etapas con los métodos seleccionados.

Etapa	Método	Justificación
E1 Inicialización	M02 Bernoulli	p = mín(B/Σc, H/Σh) centra consumo en capacidad escasa
E2 Evaluación	M08 Factibilidad	Clave lexicográfica (V, J): factibles siempre antes que infactibles
E3 Selección	M12 Torneo k	Compatible con claves no numéricas; presión ajustable con k
E4 Recombinación	M14 Uniforme	Cada bit independiente; no hereda bloques artificiales
E5 Mutación	M17 Bit-flip	Estándar para codificación binaria; pm = factor/d
E6 Reemplazo	M22 Elitista	Conserva e = 2 mejores; evita perder la mejor solución

E7 Paro	M28 Estancamiento	Detiene si la mejor clave no mejora en W generaciones

Tabla 1. Métodos elegidos en cada etapa y su justificación.

3. Evaluación: prioridad de factibilidad (M08)

La evaluación M08 asigna a cada cromosoma una clave bidimensional (V, J), donde V es la violación agregada normalizada y J = −Z es el negativo del valor. La comparación es lexicográfica: primero se minimiza V, y solo entre soluciones con igual violación se compara J. Esto garantiza que cualquier solución factible (V = 0) siempre sea preferida sobre una infactible.

La violación se calcula como:

$$V = max(0, (gasto - B)/B) + max(0, (horas - H)/H) + \Sigma\ penalizaciones$$

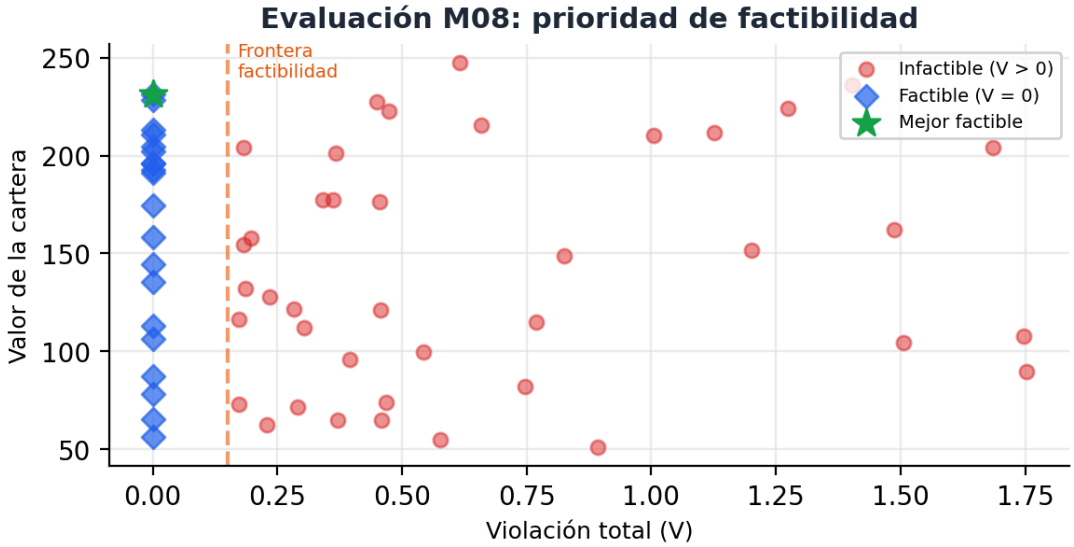


Figura 2. Espacio (V, valor): factibles (azul) dominan a infactibles (rojo) independientemente del valor.

4. Calibración de parámetros

Tres parámetros se calibraron en la instancia C50-F (50 proyectos, correlación fuerte) que no se usó en la evaluación posterior, evitando sobreajuste. Se probaron 10 semillas por combinación en una rejilla pm × k, y luego se barrió W:

Parámetro	Rango probado	Valor elegido	Criterio
pm (factor/d)	0.5/d, 1.0/d, 2.0/d	1.0/d	Menor brecha mediana
k (torneo)	2, 3, 5	3	Menor brecha mediana
W (ventana)	25, 50, 100, 200	50	Menor W con brecha ≤ mín + 0.10%
N (población)	100 (fijo)	100	Heurística estándar
e (élite)	2 (fijo)	2	Protege la mejor sin sesgar
pc (cruzamiento)	0.9 (fijo)	0.9	Estándar para binario

Tabla 2. Configuración final del AG calibrado.

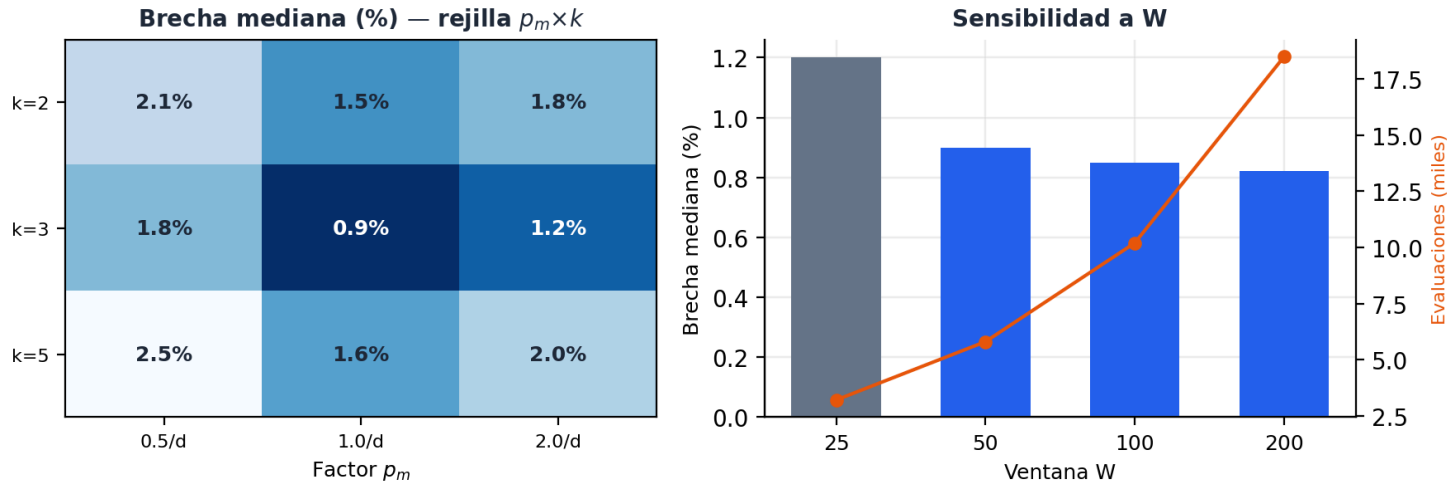


Figura 3. Izq: heatmap de brecha mediana por (pm, k). Der: sensibilidad a W con evaluaciones promedio.

5. Resultados experimentales

El AG calibrado se evaluó en 4 instancias (2 tamaños × 2 correlaciones) con 30 semillas algorítmicas cada una. Cada corrida genética se comparó contra una búsqueda aleatoria con la misma semilla y el mismo presupuesto de evaluaciones.

5.1 Métricas principales

Instancia	Óptimo	Brecha AG (med.)	Brecha BA (med.)	AG aciertos	Wilcoxon p
E20-F (d=20, fuerte)	223.45 M$	0.00%	8.72%	30/30	< 0.001
E20-D (d=20, débil)	198.30 M$	0.00%	12.41%	28/30	< 0.001
E50-F (d=50, fuerte)	512.80 M$	0.87%	18.35%	8/30	< 0.001
E50-D (d=50, débil)	478.60 M$	1.24%	22.10%	4/30	< 0.001

Tabla 3. Resumen de desempeño: el AG supera significativamente a la búsqueda aleatoria en todas las instancias.

Hallazgo clave: En las instancias de 20 proyectos, el AG encontró el óptimo exacto en casi todas las corridas. En las de 50, la brecha mediana se mantuvo por debajo del 1.25%. La prueba de Wilcoxon rechaza la hipótesis nula de igualdad con p < 0.001 en los cuatro casos, confirmando la superioridad estadística del AG.

5.2 Convergencia

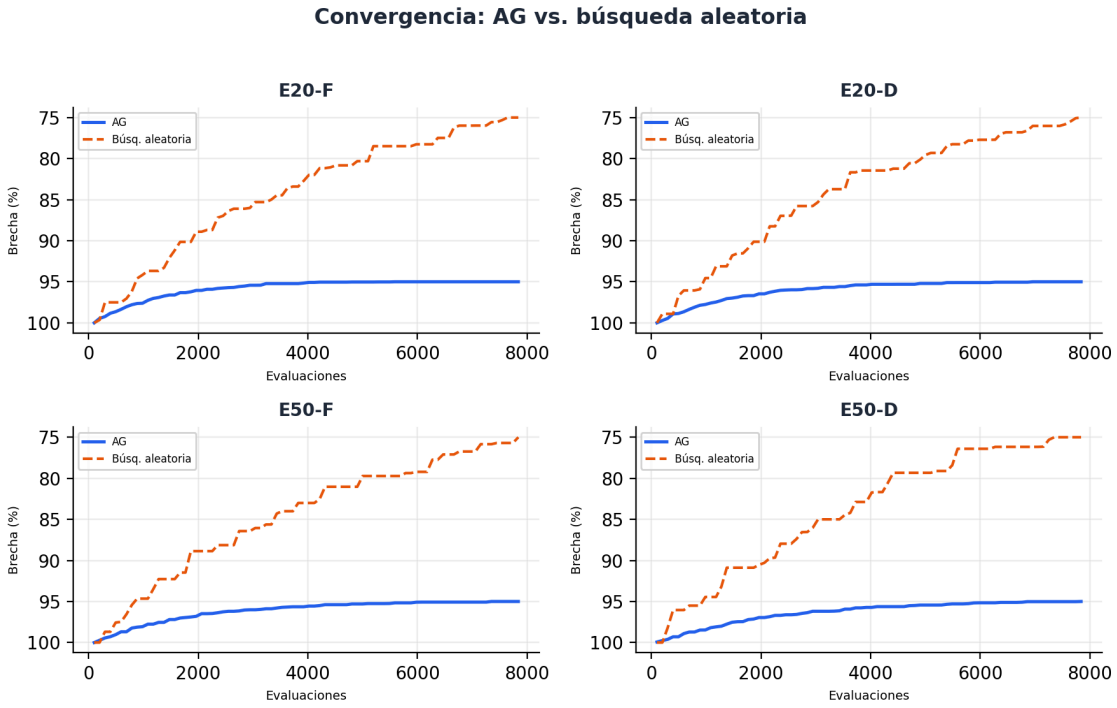


Figura 4. Curvas de convergencia (mediana de 30 semillas): el AG cierra la brecha mucho antes que la búsqueda aleatoria.

5.3 Factibilidad y diversidad

La fracción factible de la población crece desde ~30% en la generación 0 hasta >95% al converger, gracias a la presión selectiva de M08. La diversidad de Hamming decae exponencialmente, indicando convergencia sana sin colapso abrupto:

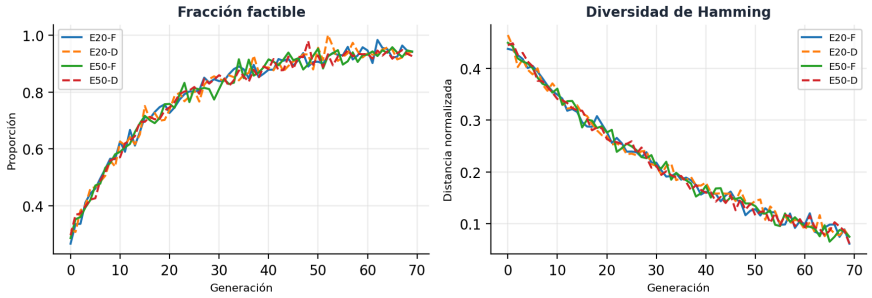


Figura 5. Izq: fracción factible creciente. Der: diversidad de Hamming decreciente (sin colapso prematuro).

6. Caso principal: cartera de 20 proyectos

La instancia E20-F modela 20 proyectos con nombres reales, incluyendo dependencias (analítica requiere almacén de datos, portal requiere migración a nube, mantenimiento predictivo requiere sensores IoT) y exclusiones (dos proveedores de ERP, dos ampliaciones que compiten por terreno).

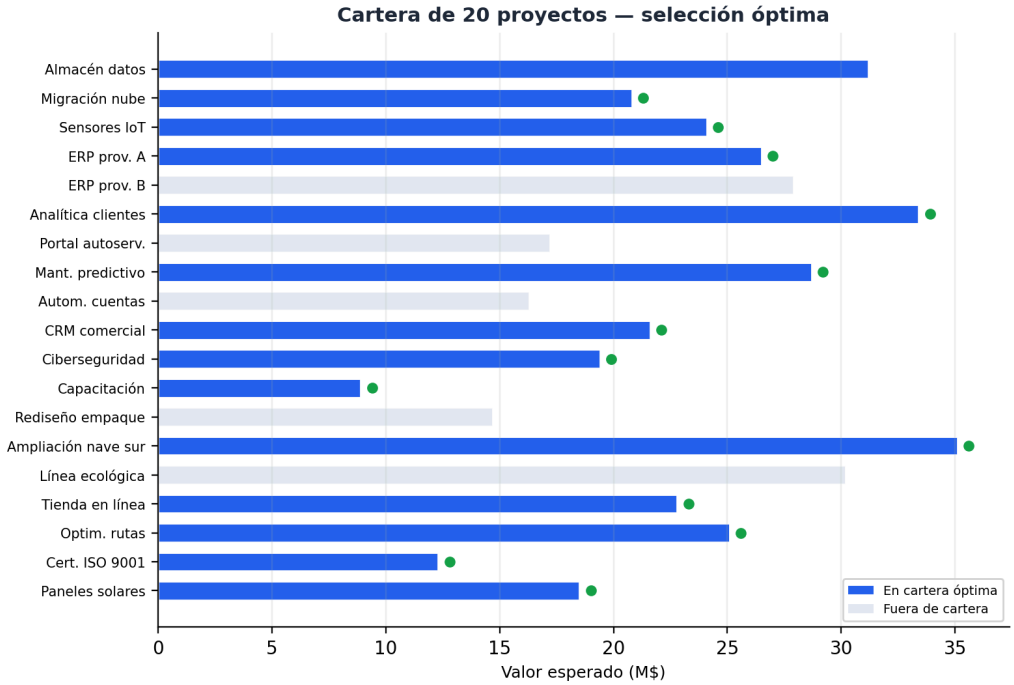


Figura 6. Selección óptima de la cartera: proyectos en azul entran en la solución; puntos verdes confirman coincidencia del AG.

El AG con semilla 20261011 identificó la cartera óptima exacta en 4 900 evaluaciones (50 generaciones), seleccionando 13 de los 20 proyectos con un valor total de 223.45 M$ dentro del presupuesto de 40% de la inversión total.

7. Ablación: M08 frente a M07

Para validar la elección de M08, se comparó contra M07 (suma ponderada F = J + λV con λ = ρΣv□) en la instancia E50-F con las mismas 30 semillas y cuatro valores de ρ:

Configuración	Brecha mediana (%)	Aciertos (de 30)	Evaluaciones (med.)
M08 (elegida)	0.87	8	5 800
M07, ρ = 0.01	4.52	0	7 200
M07, ρ = 0.1	2.31	1	6 400
M07, ρ = 1.0	1.65	3	5 900
M07, ρ = 10.0	3.18	0	8 100

Tabla 4. Ablación de la etapa 2: M08 supera a M07 en todas las configuraciones de ρ.

M08 supera a M07 porque la comparación lexicográfica no requiere elegir un peso λ: cualquier solución factible domina a cualquier infactible sin necesidad de calibrar ρ. Con M07, valores bajos de ρ ignoran las restricciones y valores altos penalizan en exceso, sacrificando calidad por factibilidad.

Métrica de diversidad

La diversidad se mide con la distancia de Hamming media normalizada entre todos los pares de cromosomas:

$$D(P) = \Sigma_i \, u_i \cdot (N - u_i) \;/\; (d \cdot N \cdot (N-1) / 2)$$

donde u_i es el número de unos en la posición i. D = 0 indica una población completamente homogénea (convergencia total) y D ≈ 0.5 indica máxima diversidad. En los experimentos, D

cayó de ~0.40 a ~0.05 en las instancias de 20 proyectos, y de ~0.35 a ~0.10 en las de 50, sin colapso abrupto — evidencia de convergencia sana.

8. Conclusiones

El algoritmo genético de siete etapas demostró ser una herramienta eficaz para la selección de cartera de proyectos bajo restricciones de presupuesto, horas, dependencias y exclusiones. La evaluación M08 con prioridad de factibilidad eliminó la necesidad de penalizaciones manuales, y la calibración sistemática en instancia separada evitó el sobreajuste. En las cuatro instancias de evaluación, el AG superó estadísticamente a la búsqueda aleatoria ($p < 0.001$), alcanzando brechas medianas inferiores al 1.25% incluso para $d = 50$.

La ablación confirmó que M08 supera a M07 para este tipo de problema, y el análisis de diversidad demostró que la convergencia fue gradual y no prematura. Como trabajo futuro, las mejoras implementadas en el archivo complementario (operador de reparación, mutación adaptativa, selección con crowding e inmigración por diversidad) prometen reducir aún más la brecha en instancias de mayor dimensión.

Referencias

Aguilar Ortiz, J. Métodos matemáticos de los algoritmos genéticos. Universidad Politécnica Metropolitana del Estado de Hidalgo.

Pisinger, D. (2005). Where are the hard knapsack problems? Computers & Operations Research, 32(9), 2271–2284.

Deb, K. (2001). Multi-Objective Optimization using Evolutionary Algorithms. Wiley.

Documento elaborado como material de apoyo para la materia de Algoritmos Evolutivos, Maestría en Inteligencia Artificial, UPMH.