UNIVERSIDAD POLITÉCNICA METROPOLITANA DE HIDALGO

Maestría en Inteligencia Artificial

Actividad 04 · Corte 2

Comparación de tres formas de recombinación y tres de mutación en un algoritmo genético para fijar precios de temporada

Alumna	Jessica Melani Romero Lora
Matrícula	25322116
Catedrático	Dr. Jaime Aguilar Ortiz
Materia	Algoritmos Evolutivos
Periodo	Septiembre–diciembre de 2026
Fecha de elaboración	14 de octubre de 2026

Link al repositorio de GitHub:

https://github.com/jessicaromero-ctrl/Evolutive-Algorithms/tree/main/ACT-04-ROMERO-LORA-JESSICA-MELANI

1. Introducción

Fijar el precio de temporada de cada producto de una categoría es una decisión comercial con restricciones reales: existencias limitadas, pisos y techos de precio, una escalera de precios entre marcas de un mismo producto y un tope al alza del índice de precios de la categoría. Hoy en la cadena de tiendas de conveniencia la regla vigente es sumar 45 % al costo, sin considerar cuánto reacciona la demanda de cada producto ni las restricciones comerciales.

Un algoritmo genético (AG) es una alternativa razonable para explorar espacios de decisión de este tipo porque no exige derivadas ni supone una forma particular de la función objetivo. Su desempeño, sin embargo, depende de cómo se realiza cada una de sus etapas. Esta actividad se propone aplicar y comparar tres formas de realizar dos de las siete etapas de un AG, y justificar la elección.

Objetivo del estudio. Determinar qué combinación de un operador de recombinación y un operador de mutación produce, con un presupuesto de evaluaciones idéntico, soluciones más cercanas al óptimo global del problema, y justificar por qué esa combinación se elige. Las etapas de recombinación y de mutación se comparan en un diseño factorial completo 3 × 3; las cinco etapas restantes se fijan.

Todos los datos son sintéticos y la demanda es lineal. Por ello el óptimo global de cada instancia puede calcularse y certificarse exactamente, lo que permite medir la brecha de cada configuración respecto al óptimo y no sólo respecto a otras configuraciones.

2. Desarrollo

2.1 Descripción del problema y modelo

Una cadena regional fija el precio de temporada de los d productos de una categoría. Los productos se agrupan en familias (por ejemplo, agua natural de 1.5 L) y cada familia tiene tres niveles: marca propia, marca estándar y marca premium. El gen j es el precio p_j en pesos, un número real. La demanda es lineal en los precios, $q(p) = a - Bp$, con efectos cruzados entre sustitutos. B es simétrica y definida positiva, así que la utilidad $\pi(p) = \Sigma(p_j - c_j)q_j(p)$ es estrictamente cóncava y su máximo sobre el conjunto factible es único.

Las reglas comerciales se escriben como $G\,p \le h$ con cada fila adimensional. La violación agregada $V(p)$ vale cero exactamente en el conjunto factible, que es un poliedro convexo.

Tabla 1. Reglas comerciales del modelo

Regla	Forma	Escala de la fila
Existencias	$q_j(p) \le S_j$	S_j
Demanda no negativa	$q_j(p) \ge 0$	q^{o}_j
Escalera de precios	$p_{superior} \ge (1 + g)\, p_{inferior}$, dentro de cada familia	$P_{superior}$
Índice de precios	$\Sigma\, w_j\, p_j / P_j \le 1 + \eta_I$, con w_j la participación en el ingreso	1

Parámetros de las instancias: piso 1.10 c_j, techo 1.20 P_j, escalera $g = 8$ %, índice $\eta_I = 3$ %.

2.2 Referencia exacta y líneas base

El óptimo global se obtiene con SLSQP desde cuatro arranques y se certifica resolviendo el sistema de Karush-Kuhn-Tucker sobre el conjunto activo, hasta que los multiplicadores sean no negativos y ninguna restricción quede violada. El AG nunca usa esta referencia: no la inicializa, no la guía y no la detiene. Se comparan dos líneas base: la regla vigente de costo más 45 % y un ajuste parejo que sube

o baja todos los precios el mismo porcentaje, recortado a la caja de cada producto. Como referencia adicional, una búsqueda aleatoria usa exactamente el mismo presupuesto de evaluaciones que el AG.

2.3 Las siete etapas y las tres formas comparadas

Las siete etapas se fijan según la guía de la materia. Cinco quedan fijas y las etapas 4 (recombinación) y 5 (mutación) se realizan de tres formas distintas. La recombinación y la mutación son las únicas etapas en que existen tres mecanismos nativos de la representación con real diferencia entre sí.

Tabla 2. Etapas del algoritmo genético

Etapa	Método	Justificación
1 · Inicialización	M03 hipercubo latino (fijo)	Recorre el rango completo de cada precio con N = 100
2 · Evaluación	M08 prioridad de factibilidad (fijo)	Compara con clave lexicográfica; sin coeficiente de penalización
3 · Selección	M12 torneo, k = 2 (fijo)	Compara claves sin convertirlas en probabilidades
4 · Recombinación	M14 · M15 · M16 (comparados)	Intercambiar, interpolar o extrapolar
5 · Mutación	M18 · M19 · M20 (comparados)	Reiniciar, perturbar con recorte, o perturbar respetando las cotas
6 · Reemplazo	M22 generacional con elitismo, e = 2 (fijo)	La mejor solución factible no se pierde
7 · Paro	M26 presupuesto de 20 000 evaluaciones (fijo)	Las nueve configuraciones gastan lo mismo

Se descartaron M13 (un punto) y M17 (inversión de bits), que no aplican o son equivalentes a M14 con precios reales.

Tabla 3. Las tres formas de recombinar y las tres de mutar

Forma	Mecanismo	¿Crea valores nuevos?	Parámetro
M14 uniforme por máscara	Cada gen se hereda de un padre u otro	No	—
M15 aritmética	El hijo cae en el segmento entre los padres	Sí, sólo entre ellos	$\alpha \sim U(0,1)$ por pareja
M16 BLX-α	El hijo se muestrea en un intervalo ampliado	Sí, también fuera	α calibrado
M18 reinicio uniforme	Precio nuevo uniforme en [ℓ, u]	Global	—
M19 gaussiana acotada	Perturbación gaussiana con recorte	Local; masa en la cota	σ calibrado
M20 polinomial acotada	Perturbación que respeta la distancia a las cotas	Local; nunca sale	η calibrado

M15 preserva la factibilidad de padres factibles por convexidad del conjunto factible; M14 y M15 conservan la suma de los padres.

2.4 Instancias de evaluación y pruebas automatizadas

Tabla 4. Instancias del estudio y líneas base

Instancia	Productos	Sustitución	Uso	Óptimo (pesos)	Mejora posible	Brecha parejo
C24-F	24	F	calibración	180,312	8.45 %	2.05 %
E12-D	12	D	evaluación	66,005	5.68 %	3.83 %
E12-F	12	F	evaluación y caso principal	60,316	8.67 %	1.97 %
E36-D	36	D	evaluación	193,210	5.30 %	2.64 %
E36-F	36	F	evaluación	257,433	8.62 %	1.86 %

Mejora posible: utilidad del óptimo sobre la regla actual. Brecha parejo: distancia del ajuste parejo al óptimo.

Antes de cualquier experimento se ejecutaron 16 pruebas automatizadas, todas aprobadas. Dos de ellas contrastan la referencia exacta con problemas resueltos a mano (un producto con techo activo y dos sustitutos simétricos), y otras verifican las propiedades que justifican cada operador: la suma conservada en M14 y M15, la factibilidad de los hijos de M15 con padres factibles, la permanencia dentro de la caja en M18, M19 y M20, y el presupuesto idéntico de la búsqueda aleatoria.

3. Continuación de la práctica

3.1 Calibración de los parámetros propios

Cada configuración calibra sólo sus propios parámetros (α de M16, σ de M19 y η de M20) en una instancia distinta de las de evaluación, C24-F, con diez semillas. La regla se fijó antes de ejecutar: se elige la celda de menor brecha mediana, y un empate se rompe con la menor brecha media. En total se realizaron 350 corridas.

Tabla 5. Parámetros elegidos en la calibración (C24-F)

Configuración	α	σ	η	Brecha mediana (%)	Brecha media (%)
M14+M18	—	—	—	1.2073	1.3023
M14+M19	—	0.05	—	0.2780	0.3242
M14+M20	—	—	20	0.4315	0.4639
M15+M18	—	—	—	0.9975	0.9829
M15+M19	—	0.10	—	0.4415	0.4327
M15+M20	—	—	20	0.4129	0.4244
M16+M18	0.3	—	—	0.9511	0.9995
M16+M19	0.3	0.05	—	0.2438	0.2489
M16+M20	0.3	—	20	0.2669	0.2655

M15+M19 eligió σ = 0.10, el extremo de la rejilla: la recombinación que contrae la población necesita la mutación más amplia.

3.2 Resultados del diseño factorial 3 × 3

Se ejecutaron 1 080 corridas genéticas (cuatro instancias, nueve configuraciones y treinta semillas emparejadas) y 120 búsquedas aleatorias con el mismo presupuesto de 19,994 evaluaciones. La Tabla 6 muestra la brecha mediana de cada combinación. La mutación M18 es la peor en las cuatro instancias, y la mejor recombinación depende del problema: M14 gana o empata en tres instancias, y M16 gana sola en la instancia grande con sustitución fuerte.

Tabla 6. Brecha mediana (%) respecto al óptimo certificado, treinta semillas

Instancia · recombinación	M18 reinicio	M19 gaussiana	M20 polinomial
E12-D · M14	0.322	0.033	0.032
E12-D · M15	0.911	0.144	0.058
E12-D · M16	0.740	0.042	0.041
E12-F · M14	0.620	0.088	0.074
E12-F · M15	0.878	0.190	0.110
E12-F · M16	0.727	0.073	0.079
E36-D · M14	0.769	0.079	0.073
E36-D · M15	0.890	0.210	0.300
E36-D · M16	0.756	0.088	0.098
E36-F · M14	1.408	0.548	0.474
E36-F · M15	0.931	0.461	0.698
E36-F · M16	0.841	0.365	0.331

Los valores más bajos son mejores. Las brechas se reportan con tres decimales porque las diferencias entre configuraciones son pequeñas.

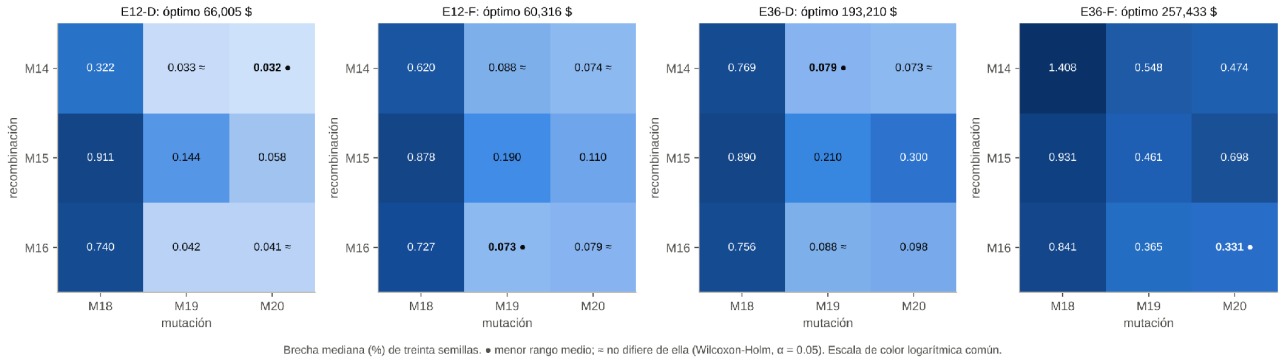


Figura 1. Brecha mediana por instancia, recombinación y mutación. Escala de color logarítmica común.

3.3 Pruebas estadísticas y elección final

La prueba de Friedman rechaza la igualdad de las nueve configuraciones en el ranking global de 120 bloques ($\chi^2 = 735.1$, $p \approx 2 \times 10^{-153}$). Las comparaciones contra la mejor configuración usan la prueba posterior de Demšar con corrección de Holm. Cuatro configuraciones forman un grupo superior sin diferencias estadísticas entre sí. Según la regla fijada de antemano, entre ellas se elige la de menor brecha máxima: M16+M20, con $\alpha = 0.3$ y $\eta = 20$, cuya peor corrida queda a 0.575 % del óptimo.

Tabla 7. Ranking global sobre 120 bloques (menor rango es mejor)

Configuración	Rango medio	p (Holm)	Brecha mediana (%)	Brecha máxima (%)
M16+M19	2.592	—	0.078	0.630
M14+M20	2.700	1.000	0.073	1.804
M16+M20	2.758	1.000	0.091	0.575
M14+M19	2.992	0.774	0.084	1.718
M15+M20	5.050	< 0.001	0.225	1.020
M15+M19	5.167	< 0.001	0.202	0.757
M16+M18	7.600	< 0.001	0.773	1.326
M14+M18	7.800	< 0.001	0.691	3.915
M15+M18	8.342	< 0.001	0.897	1.445

p (Holm): valor p de la comparación contra la configuración de menor rango medio, ajustado por Holm.

3.4 Mecanismos y caso principal

En E36-F, con mutación M19 y en la generación 10, la recombinación M15 contrae la población con mayor rapidez: su dispersión es 0.0335, frente a 0.1932 con M14. Su ventaja de factibilidad es igual de clara: la fracción de hijos factibles es 0.93 con M15 y 0.00 con M14. Esa rapidez no se traduce en mejor precisión al final del presupuesto, y por eso M15 nunca entra al grupo superior.

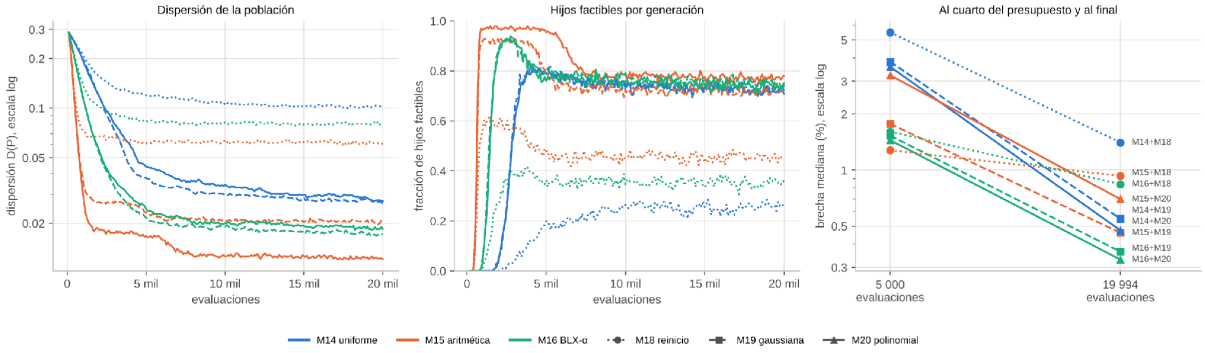


Figura 2. Dispersión de la población, fracción de hijos factibles y brecha al cuarto y al final del presupuesto (E36-F).

Para el caso principal de E12-F (doce bebidas), la corrida de M16+M20 con la primera semilla obtiene un resultado a 0.088 % del óptimo y captura el 98.9 % de la mejora posible. El óptimo sube los precios premium y compensa el límite del índice con bajas de hasta 2.9 %. Redondear el óptimo a diez centavos cuesta 0.0071 % de utilidad, por lo que la utilidad es muy plana cerca del óptimo.

Tabla 8. Caso principal E12-F: alternativas comparadas

Alternativa	Utilidad (pesos)	Brecha (%)	Mejora capturada (%)	Factible
Precios actuales (costo más 45 %)	55,503	7.980	0.0	Sí
Ajuste parejo (+3.00 %)	59,131	1.965	75.4	Sí
AG M16+M20, semilla 20261017	60,263	0.088	98.9	Sí
AG M15+M18, semilla 20261017	59,791	0.870	89.1	Sí
Óptimo redondeado a 50 centavos	60,447	-0.216	102.7	No
Óptimo redondeado hacia abajo a 50 centavos	58,417	3.148	60.5	No
Óptimo redondeado a 10 centavos	60,312	0.007	99.9	Sí
Óptimo certificado	60,316	0.000	100.0	Sí

Los redondeos a 50 centavos rompen el índice de precios o las existencias, por lo que no son factibles.

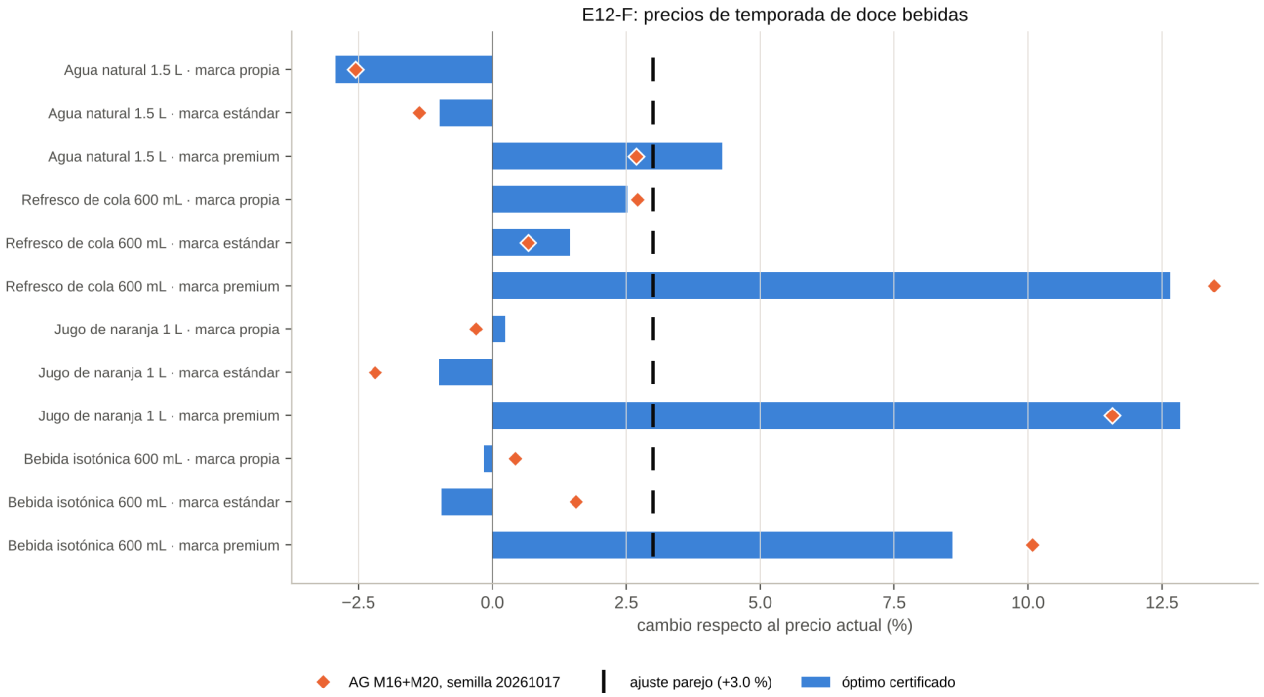


Figura 3. Cambio porcentual por producto en el óptimo, en la corrida del AG y en el ajuste parejo.

4. Conclusiones

La justificación de la elección entorno a los métodos M14 y M16 con mutación local forman el grupo superior, y se elige M16+M20 con $\alpha = 0.3$ y $\eta = 20$ porque tiene la menor brecha máxima entre las configuraciones estadísticamente equivalentes.Por otra parte, la mutación pesa más que la recombinación reiniciar el precio (M18) es la peor forma de mutar en las cuatro instancias; las perturbaciones locales (M19 y M20) capturan la mayor parte de la mejora posible. La recombinación depende del problema M15 produce hijos factibles casi siempre por la convexidad del conjunto factible, pero contrae la población y no alcanza al final. M16 gana cuando la sustitución es fuerte.

El valor práctico con el mismo presupuesto, se respeta observando el AG, el cual captura entre el 95 % y el 99 % de la mejora posible, mientras que la búsqueda aleatoria no encuentra soluciones factibles en las instancias de 36 productos. La limitación de la utilidad es cóncava y las reglas son lineales, así que un solucionador de programación cuadrática resuelve cada instancia en menos de 0.11 s. El AG tiene sentido práctico con demanda no cóncava o reglas no lineales, y entonces cambiaría la etapa de evaluación. Aquí es el objeto de estudio, no la herramienta de producción, esta aclaración y observación son fundamentales para desarrollar soluciones con capacidad de despliegue en entornos empresariales en donde los algoritmos evolutivos sean desarrollados de manera conjunta.

5. Referencias

Blickle, T., y Thiele, L. (1996). A comparison of selection schemes used in evolutionary algorithms. Evolutionary Computation, 4(4), 361–394.

Boyd, S., y Vandenberghe, L. (2004). Convex optimization. Cambridge University Press.

Deb, K. (2000). An efficient constraint handling method for genetic algorithms. Computer Methods in Applied Mechanics and Engineering, 186(2–4), 311–338.

Deb, K., y Deb, D. (2014). Analysing mutation schemes for real-parameter genetic algorithms. International Journal of Artificial Intelligence and Soft Computing, 4(1), 1–28.

Deb, K., y Goyal, M. (1996). A combined genetic adaptive search (GeneAS) for engineering design. Computer Science and Informatics, 26(4), 30–45.

Demšar, J. (2006). Statistical comparisons of classifiers over multiple data sets. Journal of Machine Learning Research, 7, 1–30.

Eshelman, L. J., y Schaffer, J. D. (1993). Real-coded genetic algorithms and interval-schemata. En Foundations of Genetic Algorithms 2 (pp. 187–202). Morgan Kaufmann.

Holm, S. (1979). A simple sequentially rejective multiple test procedure. Scandinavian Journal of Statistics, 6(2), 65–70.

McKay, M. D., Beckman, R. J., y Conover, W. J. (1979). A comparison of three methods for selecting values of input variables in the analysis of output from a computer code. Technometrics, 21(2), 239–245.