UNIVERSIDAD POLITÉCNICA METROPOLITANA DE HIDALGO

Maestría en Inteligencia Artificial

Reporte técnico · Corte 2 · Actividad Previa 08

Algoritmos genéticos para la producción minera polimetálica: mezcla, secuenciamiento y molienda con enfoque regional en Hidalgo

Materia: Algoritmos Evolutivos

Alumna	Jessica Melani Romero Lora
Matrícula	25322116
Catedrático	Dr. Jaime Aguilar Ortiz
Modalidad	Individual
Periodo	Septiembre–diciembre de 2026
Fecha de entrega	21 de octubre de 2026

Código fuente:

https://github.com/jessicaromero-ctrl/Evolutive-Algorithms/tree/main/Actividades%20Previas/actividad%20previa%2008

1. Introducción y contexto regional

La minería metálica en México enfrenta un problema de decisión con horizontes distintos: la mezcla diaria de mineral que llega a la planta, la secuencia de frentes que se extraen en los próximos años y los ajustes de operación del circuito de molienda. Cada decisión combina restricciones físicas, económicas y de calidad, y su efecto sobre el valor del negocio es no lineal. Los algoritmos evolutivos son adecuados para estas decisiones cuando el modelo de planta es complejo o solo puede evaluarse por simulación [1][2][13].

Hidalgo es un estado con tradición minera. El distrito de Zimapán, en el norte, concentra operaciones de zinc, plomo y plata. En 2021 la empresa SantaCruz Silver adquirió la planta de Zimapán, con capacidad de 75 000 toneladas secas por mes y circuitos de zinc, plomo y cobre, por un monto de US$20 millones más IVA de US$3.2 millones [15]. La inversión privada comprometida en el estado asciende a MX$147.7 mil millones en 130 proyectos, de los cuales 75 están en operación, 23 en construcción y 22 en planeación o trámite.

Ese monto se concentra sobre todo en cemento, infraestructura y manufactura [16]. En el ámbito nacional, el valor de la producción minera alcanzó en 2025 un máximo histórico de MX$379.3 mil millones, con un aumento de 21.2 % en valor y un volumen prácticamente sin cambio; el valor de la plata creció 34.9 % [17]. Esa combinación, precios altos y volumen estable, favorece las inversiones que mejoran la eficiencia de la operación existente sobre las que amplían la capacidad.

Este reporte sostiene que, en ese contexto, la optimización algorítmica de la operación es una inversión de costo relativamente bajo frente a la infraestructura, y que su valor depende de la calidad del modelo y de la validación con datos de planta. Se desarrollan tres escenarios: mezcla de mineral de cinco frentes, secuenciamiento de bloques con capacidad y precedencias y ajuste de molienda. Los parámetros son ilustrativos y no provienen de ninguna operación real; el objetivo es analizar la estructura del problema y el comportamiento de los métodos.

2. Referentes previos

La optimización de mezclas de mineral se formula clásicamente como un programa lineal cuando la recuperación es constante [3]. Cuando la recuperación depende de la ley y de las impurezas, el problema se vuelve no lineal y se han usado métodos metaheurísticos para resolverlo [4]. La evolución diferencial es un método de búsqueda sin gradientes que se usa como referencia en problemas continuos de este tipo [5].

El secuenciamiento de extracción con restricciones de capacidad y precedencia es un problema entero que puede resolverse con programación lineal entera mixta [6][7]. En problemas de tamaño industrial los algoritmos genéticos se han aplicado para obtener buenas soluciones en tiempos cortos, a costa de garantías de optimalidad [8][9]. La reparación de soluciones infactibles es una práctica frecuente para mantener la factibilidad durante la búsqueda [10].

El control de los circuitos de molienda se ha abordado con modelos de respuesta y optimización de consigna, combinados con restricciones de tamaño de partícula y potencia [11][12]. En Hidalgo, la formación de especialistas en minería y metalurgia se realiza en instituciones como la Universidad Autónoma del Estado de Hidalgo, que participa en comités educativos de la industria [18].

3. Fundamentos matemáticos

Los tres escenarios son instancias del problema general de la ecuación (1). Lo que cambia es el dominio, que determina la codificación, y la función de valor, que determina la dificultad de la búsqueda. La decisión de método depende de la estructura de esa función, por lo que conviene revisar antes la formulación de cada problema.

$$x^{*} = \arg\max_{x \in X} V(x) \quad \text{sujeto a} \quad g(x) \le 0 \qquad (1)$$

3.1 Mezcla de mineral (escenario 1)

Sean p_k la proporción del frente k en la alimentación, z_k su ley de zinc (%), a_k su impureza equivalente (ppm) y c_k su costo de extracción y acarreo (USD/t). Con recuperación constante R_0, el problema es lineal:

$$\max \sum_k p_k (P \cdot z_k/100 \cdot R_0 - c_k - C_{proc}) \quad \text{s.a.} \quad \sum_k p_k = 1,\ \sum_k z_k p_k \ge Z_{min},\ \sum_k a_k p_k \le A_{max},\ p \ge 0 \qquad (2)$$

Cuando la recuperación depende de la ley media $\bar{z} = \sum p_k z_k$ y de la impureza media $\bar{a} = \sum p_k a_k$, la utilidad deja de ser lineal. Usamos una forma hiperbólica en ambas variables:

$$r(\bar{z}, \bar{a}) = R_{max} \cdot \frac{\bar{z}}{\bar{z} + K_z} \cdot \frac{1}{1 + \bar{a}/A_{ref}}, \quad U(p) = P \cdot (\bar{z}/100) \cdot r - \sum_k p_k c_k - C_{proc} \qquad (3)$$

Las restricciones de calidad se imponen con penalización lineal: $U_{pen}(p) = U(p) - 500 \cdot \max(0, Z_{min} - \bar{z}) - 0.5 \cdot \max(0, \bar{a} - A_{max})$. El AG usa $u \in [0,1]^5$ y proyecta u al símplex con $w_k = u_k / \sum_j u_j$, como en los escenarios de fusión del reporte previo de este proyecto.

3.2 Secuenciamiento de frentes (escenario 2)

Sean τ_j el tonelaje del bloque j (kt), v_j su valor neto (MUSD), r la tasa de descuento y $x_{jt} \in \{0,1\}$ la decisión de extraer el bloque j en el periodo t. El modelo entero es:

$$\max \sum_j \sum_t v_j (1+r)^{-t} x_{jt} \quad \text{s.a.} \quad \sum_t x_{jt} \le 1,\ \sum_j \tau_j x_{jt} \le C,\ \sum_{\tau<t} x_{a\tau} \ge x_{bt} \qquad (4)$$

La restricción de precedencia exige que el bloque a se extraiga antes que el bloque b. El AG usa un gen real $g_j \in [0, T+1)$ por bloque y decodifica $t_j = \lfloor g_j \rfloor$, donde $t_j = 0$ significa no extracción. La reparación elimina, en cada periodo con sobrecarga, el bloque de menor valor descontado, y después elimina las extracciones que violan precedencia. Con reparación, cada solución evaluada es factible.

3.3 Ajuste de molienda (escenario 3)

Sean *n* la fracción de velocidad crítica, J la carga de bolas (%) y Q la alimentación (t/h). Usamos un modelo sustituto con las siguientes relaciones, cuyos coeficientes son ilustrativos:

P80 = P_A (Q/120)^0.5 e^(−2.2(n−0.70)) (J/32)^(−0.6), P = P_B n^1.5 (J/32)^0.9 (0.6 + 0.4Q/120) (5)

R = R_max [1 − e^(−(P_ref/P80)^1.5)], V = Q (V_T·R − C_M) − C_E·P (6)

El problema es maximizar V sujeto a P80 ≤ 150 µm y P ≤ 1000 kW, con una tolerancia relativa de 0.5 % en ambas restricciones para la evaluación de factibilidad. La ecuación (5) implica que un aumento de la velocidad reduce el tamaño de partícula pero eleva la potencia, y que el aumento de Q eleva el rendimiento pero engruesa el producto; el óptimo se encuentra en la frontera definida por ambas restricciones.

3.4 Relación entre los elementos y sensibilidad económica

Dos relaciones conectan los escenarios con la decisión de inversión. La primera es que la ecuación (2) es exacta cuando la recuperación es constante, de modo que un solver lineal da el óptimo global; la ecuación (3) rompe esa linealidad y, con ella, la garantía de optimalidad. La segunda es de orden económico: la ley media de la mezcla óptima, $\bar{z}$ = 7.67 %, define la sensibilidad de la utilidad a la recuperación. Para la planta de Zimapán (75 000 t/mes, es decir 900,000 t/año), un punto porcentual de recuperación de zinc vale del orden de USD 1.93 millones al año en valor bruto, con precio de referencia de USD 2 800/t. Ese número no incluye costos ni supone un precio ni una ley reales; sirve para dimensionar el orden de magnitud frente a inversiones de instrumentación o de software de optimización.

ΔV_anual = Δr · T_anual · P · $\bar{z}$/100 (7)

4. Método común

Los tres escenarios usan el núcleo de algoritmo genético del proyecto (ga_comun.py), con 40 individuos, 50 generaciones, elitismo de dos individuos, torneo binario, cruce BLX-α con α = 0.3 y mutación gaussiana con σ = 0.05 (escenarios 1 y 3) y, en el escenario 2, codificación real con decodificación por piso. Cada ejecución consume 1 940 evaluaciones. La búsqueda aleatoria de control usa el mismo número, y en el escenario 1 se añade evolución diferencial de SciPy como referencia de un método robusto sin presupuesto fijo. Se usan cinco semillas por escenario (11, 23, 37, 53, 71). Como referencia exacta se usa programación lineal (escenario 1, modelo lineal), MILP con HiGHS (escenario 2) y malla densa con refinamiento local (escenario 3).

5. Escenario 1: mezcla de mineral de cinco frentes

Se consideran cinco frentes con leyes de zinc entre 4.1 % y 11.4 %, costos entre 12 y 24 USD/t e impurezas entre 80 y 1 200 ppm. La planta exige una ley media mínima de 6.0 %

y una impureza media máxima de 400 ppm. Estos valores son ilustrativos. Primero se resuelve el modelo lineal con programación lineal, que da el óptimo exacto de USD 160.47/t. Luego se resuelve el modelo no lineal de la ecuación (3), donde el AG y la evolución diferencial se comparan con la búsqueda aleatoria y con la solución lineal evaluada en el modelo no lineal.

En el modelo lineal, el AG alcanza una utilidad media de 155.01 USD/t, con desviación de 1.36, es decir, 5.45 USD/t por debajo del óptimo exacto (3.4 %). La causa es la penalización blanda: las soluciones del AG quedan en el interior de la región cercana a la restricción de impureza, en lugar de apoyarse sobre ella. Esto muestra un punto de diseño importante: cuando el modelo es lineal y el solver existe, la programación lineal es preferible. El AG se justifica cuando la ecuación (3) impide esa formulación.

En el modelo no lineal, la mejor solución es una mezcla pura del frente 2, con utilidad de 90.63 USD/t. El AG llega a esa solución en 4 de cinco semillas y la evolución diferencial en 5 de cinco; la búsqueda aleatoria alcanza una utilidad media de 86.24 USD/t. La solución lineal, evaluada en el modelo no lineal, da 88.12 USD/t: la pérdida de 2.51 USD/t es el costo de usar un modelo lineal cuando la recuperación depende de la mezcla. La figura 1 resume la convergencia, la distribución de utilidades y la composición de la mezcla.

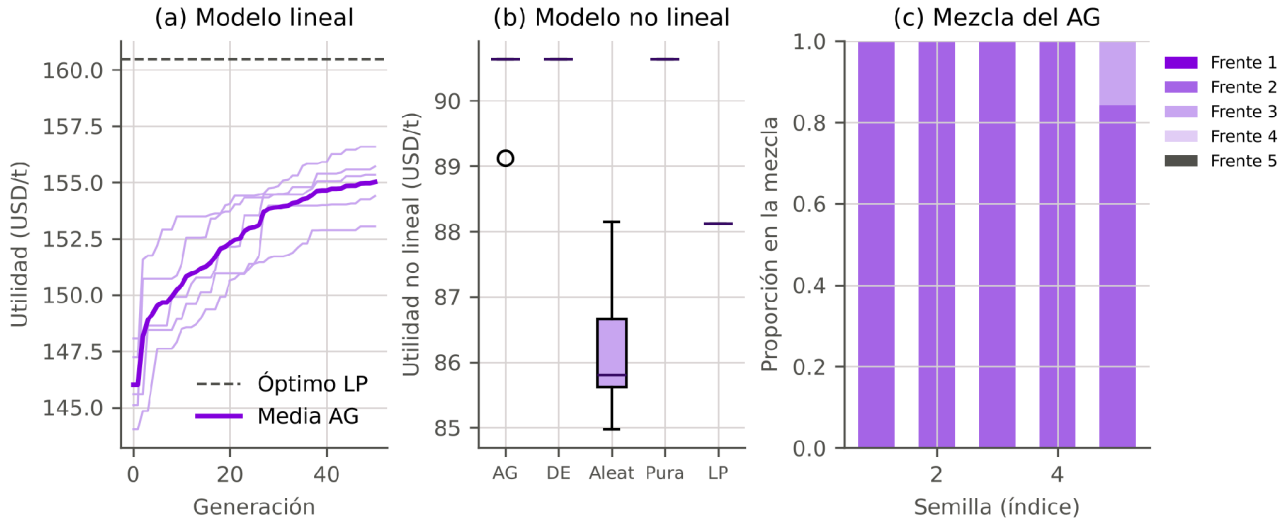


Figura 1. (a) Convergencia del AG en el modelo lineal frente al óptimo LP; (b) utilidad en el modelo no lineal por método; (c) proporciones de la mezcla por semilla.

6. Escenario 2: secuenciamiento de frentes con capacidad y precedencias

Se consideran 15 bloques, cuatro periodos, una tasa de descuento de 10 % y una capacidad de planta de 260 kt por periodo. Tres pares de precedencia obligan a extraer ciertos bloques después de otros. El MILP resuelto con HiGHS da un VPN óptimo de 131.19 MUSD y extrae 13 de 15 bloques. Es el valor de referencia exacto del problema.

El AG con reparación obtiene un VPN medio de 126.85 MUSD, con brecha media de 4.34 MUSD (3.3 %) y factibilidad en las cinco semillas. Con penalización débil (0.5 MUSD por

kt excedido), el AG encuentra soluciones de VPN mayor que el óptimo en algunas semillas, pero son infactibles: en 2 de cinco ejecuciones la mejor solución viola la capacidad o la precedencia, lo que la vuelve inutilizable. Con penalización fuerte (5 MUSD por kt), todas las soluciones son factibles, pero el VPN medio cae a 111.55 MUSD: la penalización fuerte hace que la búsqueda rechace casi todas las soluciones cercanas a la frontera de capacidad, que es donde está el óptimo. Este resultado justifica la reparación como operador de factibilidad frente a la penalización.

La figura 2 muestra la secuencia óptima, la carga por periodo frente a la capacidad, y la convergencia del AG con reparación. El óptimo usa la capacidad casi completa en los periodos 1 a 3. Para la planta, la lección operativa es que la ganancia de secuenciar bien proviene de nivelar la carga, no de maximizar la extracción de un solo periodo.

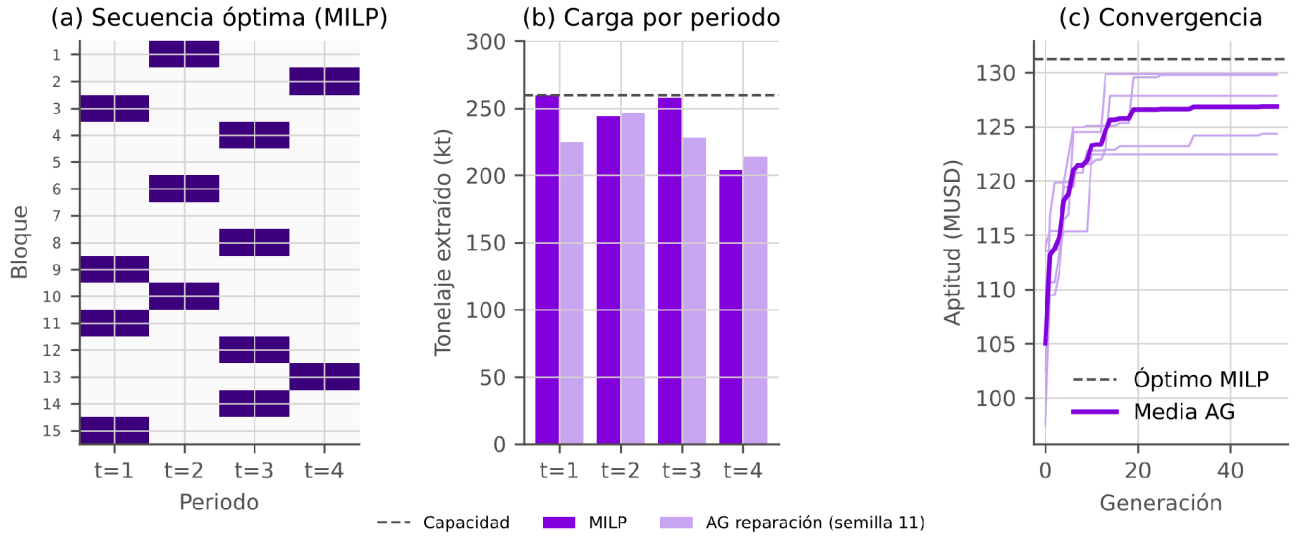


Figura 2. (a) Secuencia óptima por bloque y periodo (MILP); (b) carga por periodo frente a la capacidad; (c) convergencia del AG con reparación frente al óptimo.

7. Escenario 3: ajuste de la molienda con restricciones de planta

El escenario 3 representa el ajuste de consignas de un circuito de molienda con un modelo sustituto. El ajuste por defecto (velocidad 0.78, carga de bolas 30 %, alimentación 100 t/h) produce un P80 de 143.2 µm y una potencia de 728 kW, dentro de especificación, con un valor de USD 3,855/h. La referencia de malla densa con refinamiento local ajusta la velocidad al límite superior, la alimentación al límite de 150 t/h y la potencia al límite de 1000 kW, con un valor de USD 5,582/h. La mejora es de USD 1,728/h, es decir 44.8 %.

El AG encuentra una solución de 5,568 USD/h en promedio, con cuatro de cinco semillas dentro de 0.1 % de la referencia. La semilla 71 queda en 5,511 USD/h, 1.3 % por debajo, porque la búsqueda se estanca cerca de una frontera. La búsqueda aleatoria llega a un valor medio de 5,480 USD/h, unos 1.8 % por debajo de la referencia. Nelder–Mead, iniciado en la configuración por defecto, converge a la referencia en las cinco semillas (5,582.4 USD/h). En esta superficie, suave y de tres variables, un método local con buen punto de partida supera al AG. El AG es más útil cuando la superficie es multimodal, por

ejemplo cuando el modelo se calibra con datos ruidosos y aparecen varios máximos locales. La figura 3 muestra el valor en el plano (n, J) con las dos fronteras de restricción, la convergencia y la comparación por método.

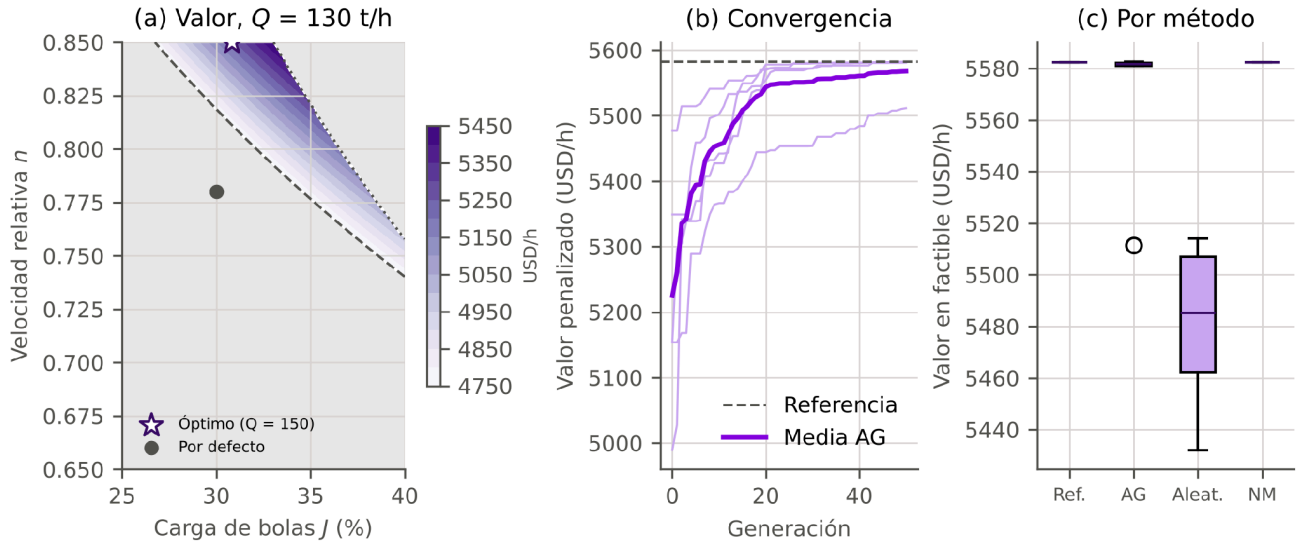


Figura 3. (a) Valor en el plano (n, J) para Q = 130 t/h; la zona gris es infactible; (b) convergencia del AG frente a la referencia; (c) valor en factible por método.

8. Aplicación industrial y necesidades de inversión en Hidalgo

La optimización de operación compite por recursos con inversiones de otra naturaleza, como la ampliación de la planta, nuevos frentes o instrumentación. Los resultados sugieren una secuencia de decisiones razonables. Primero, la optimización de la mezcla y de la molienda exige datos de planta de calidad: leyes por frente, recuperaciones por ley y potencia en tiempo real. Sin esos datos, el modelo es una hipótesis y no una herramienta. Segundo, la optimización de secuencia requiere una base de planeación minera confiable, mientras que la de molienda puede arrancar con sensores y un modelo sustituto calibrado con historiales de operación.

El orden de magnitud de los beneficios es el siguiente. En el escenario 2, la brecha media entre el AG con reparación y el óptimo exacto es de 4.34 MUSD sobre cuatro periodos, pero la diferencia entre el óptimo y una secuencia no optimizada puede ser mayor, y no fue calculada en este estudio. En el escenario 3, el ajuste de consignas aporta USD 1,728/h en el modelo sustituto. Con el número de horas de operación de una planta de este tamaño, la cifra no es despreciable frente al costo de un sistema de cómputo y de sensores. Como cálculo de dimensionamiento, la ecuación (7) con los supuestos del escenario 1 muestra que cada punto de recuperación vale del orden de USD 2 millones al año en la planta de referencia. La decisión de inversión debe basarse en la mejora demostrada con datos propios.

Para el estado, las necesidades principales son tres. La primera es capital humano en ingeniería de procesos y ciencia de datos con capacidad para calibrar modelos de planta. La segunda es infraestructura de energía y agua, dado que los circuitos de molienda

concentran el consumo eléctrico; los cambios de consigna sólo son valiosos si la red y el suministro de agua lo permiten. La tercera es una cadena de proveedores de instrumentación y software en la región, que reduce el costo de implantación. El crecimiento de la inversión privada en parques industriales, con inversiones públicas de MX$52.8 millones en modernización de parques en 2026 [19], abre la posibilidad de que estos servicios se instalen cerca de los centros mineros y de manufactura.

Una limitación es que el estado no tiene una base pública y actualizada de producción minera por municipio que permita calibrar los modelos con datos locales. Este estudio no sustituye esa información. Un paso útil sería que las empresas y las instituciones académicas compartieran series de planta bajo acuerdos de confidencialidad, de modo que los modelos se validan con datos reales antes de decidir inversiones.

9. Discusión

Tres resultados son transferibles a cualquier operación de minería metálica. Primero, la formulación importa más que el método: cuando la función es lineal, un solver exacto supera a cualquier metaheurística; cuando es no lineal, el AG y la evolución diferencial alcanzan el mismo óptimo y la búsqueda aleatoria no. Segundo, la factibilidad debe gestionarse explícitamente. La penalización débil produce soluciones inutilizables y la penalización fuerte bloquea la búsqueda. La reparación resulta más estable en el problema de secuencia. Tercero, la molienda es un caso en el que un método local bien inicializado es competitivo, y el AG sirve más para explorar cuando se reconoce multimodalidad.

Las limitaciones son claras. Todos los parámetros son ilustrativos y los datos no provienen de una operación real. Las comparaciones usan cinco semillas. La optimización no modela incertidumbre geológica, variabilidad de la ley en el tiempo ni fallas de equipo. Los resultados describen métodos y estructuras de problema; no son recomendaciones de operación.

10. Conclusiones

Los algoritmos genéticos son útiles en tres problemas de minería polimetálica cuando la formulación es no lineal, la secuencia tiene restricciones enteras o el modelo de molienda se evalúa por simulación. En los casos lineales y convexos, la programación lineal o entera ofrece el óptimo global con menor costo. Para Hidalgo, la oportunidad está en combinar la calidad de datos de planta con modelos de optimización y en formar capacidad local para mantenerlos. La inversión en esa capacidad es pequeña frente a la infraestructura y puede justificarse con una prueba piloto en una planta de la región.

Referencias

[1] Holland, J. H. (1975). Adaptation in Natural and Artificial Systems. University of Michigan Press.

[2] Eiben, A. E., & Smith, J. E. (2015). Introduction to Evolutionary Computing (2.ª ed.). Springer.

[3] Dantzig, G. B. (1963). Linear Programming and Extensions. Princeton University Press.

[4] Goldberg, D. E. (1989). Genetic Algorithms in Search, Optimization, and Machine Learning. Addison-Wesley.

[5] Storn, R., & Price, K. (1997). Differential evolution: A simple and efficient heuristic for global optimization over continuous spaces. Journal of Global Optimization, 11(4), 341–359.

[6] Lerchs, H., & Grossmann, I. F. (1965). Optimum design of open-pit mines. Transactions of the CIM, 58, 47–54.

[7] Chicoisne, R., Espinoza, D., Goycoolea, M., Moreno, E., & Rubio, E. (2012). A new algorithm for the open-pit mine scheduling problem. Operations Research, 60(3), 517–528.

[8] Goldberg, D. E., & Lingle, R. (1985). Alleles, loci, and the traveling salesman problem. En Proceedings of the First International Conference on Genetic Algorithms, 154–159.

[9] Lamghari, A., & Dimitrakopoulos, R. (2012). A diversified Tabu search approach for the open-pit mine production scheduling problem with metal uncertainty. European Journal of Operational Research, 222(3), 642–652.

[10] Michalewicz, Z., & Schoenauer, M. (1996). Evolutionary algorithms for constrained parameter optimization problems. Evolutionary Computation, 4(1), 1–32.

[11] Austin, L. G., Klimpel, R. R., & Luckie, P. T. (1984). Process Engineering of Size Reduction: Ball Milling. SME-AIME.

[12] Napier-Munn, T. J., Morrell, S., Morrison, R. D., & Kojovic, T. (1996). Mineral Comminution Circuits: Their Operation and Optimisation. Julius Kruttschnitt Mineral Research Centre.

[13] Deb, K. (2001). Multi-Objective Optimization using Evolutionary Algorithms. Wiley.

[14] Mitchell, M. (1996). An Introduction to Genetic Algorithms. MIT Press.

[15] NS Energy (2021). SantaCruz Silver enters definitive agreement to acquire the Zimapán mine and arranges financing for transaction. https://www.nsenergybusiness.com/news/santacruz-silver-enters-definitive-agreement-to-acquire-the-zimapan-mine-and-arranges-financing-for-transaction/

[16] Mexico Business News (2026). Hidalgo private investment reaches MX$147.7 billion. https://mexicobusiness.news/trade-and-investment/news/hidalgo-private-investment-reaches-mx1477-billion

[17] Mexico Business News (2026). Mining value up 21% in 2025 despite flat volume: CAMIMEX. https://mexicobusiness.news/mining/news/mining-value-21-2025-despite-flat-volume-camimex

[18] Universidad Autónoma del Estado de Hidalgo (2025). UAEH se incorpora al Comité Educativo de Minería México 2025. https://www.uaeh.edu.mx/noticias/9861

[19] Clúster Industrial (2026). Hidalgo destina MX$52.8 mdp en 2026 para modernizar parques industriales clave. https://clusterindustrial.com.mx/hidalgo-destina-mas-de-52-8-mdp-en-2026-para-modernizar-parques-industriales-clave/

Anexo. Código y reproducción

Archivo	Contenido
ga_comun.py	Núcleo del AG (codificación real y binaria) y búsqueda aleatoria de control
esc1_mezcla.py	Escenario 1: LP, modelo no lineal de recuperación, AG y DE; figura 1
esc2_secuenciamiento.py	Escenario 2: MILP exacto, AG con reparación y penalizaciones; figura 2
esc3_molienda.py	Escenario 3: modelo sustituto, malla de referencia, AG, NM y aleatoria; figura 3
construir_mineria.py	Genera este reporte a partir de resultados/*.json
docx_utils.py	Utilidades de formato del documento

Link a repositorio de GitHub:

https://github.com/jessicaromero-ctrl/Evolutive-Algorithms/tree/main/Actividades%20Previas/actividad%20previa%2008