**UNIVERSIDAD POLITÉCNICA METROPOLITANA DE HIDALGO**

Maestría en Inteligencia Artificial · Algoritmos Evolutivos

# Optimización multiobjetivo de hiperparámetros de un modelo de inteligencia artificial

## Comparación de NSGA-II, MOEA/D y búsqueda aleatoria frente al frente de Pareto exacto

### *Conceptos básicos de optimización multiobjetivo y algoritmos evolutivos multiobjetivo (MOEA)*



| | |
|---|---|
| **Alumna** | Jessica Melani Romero Lora |
| **Matrícula** | 25322116 |
| **Materia** | Algoritmos Evolutivos — Maestría en Inteligencia Artificial |
| **Docente** | Dr. Jaime Aguilar Ortiz |
| **Periodo** | Septiembre–diciembre de 2026 · Corte 2 |



## 1. Introducción

Entrenar un modelo de inteligencia artificial implica elegir hiper parámetros, como el número de capas, la tasa de aprendizaje o el tamaño del lote. Esas decisiones afectan a varios criterios que suelen estar en conflicto: el error de generalización, el costo computacional del entrenamiento y el tamaño del modelo. Un modelo más grande suele generalizar mejor, pero cuesta más entrenarlo y desplegarlo. Por eso el ajuste de hiperparámetros es, por naturaleza, un problema **multiobjetivo**: no existe una única solución óptima, sino un conjunto de compromisos.

Esta actividad aplica un algoritmo evolutivo multiobjetivo (MOEA) a ese problema con datos reales de clasificación. Los objetivos son minimizar el error de validación cruzada, minimizar el costo de entrenamiento y minimizar el número de parámetros. Se compara NSGA-II y MOEA/D con una búsqueda aleatoria, a presupuesto de evaluaciones idéntico. Los resultados se contrastan con el frente de Pareto exacto, que se obtiene evaluando todo el espacio de decisión.

## 2. Conceptos básicos de optimización multiobjetivo

Un problema multiobjetivo de minimización consiste en encontrar decisiones x dentro de un espacio factible X que minimicen simultáneamente m funciones objetivo:

$$\min F(x) = (f_1(x), f_2(x), ..., f_m(x)), \quad x \in X$$

Una solución x **domina** a otra y (escrito $x \prec y$) si no es peor en ningún objetivo y es estrictamente mejor en al menos uno:

$$x \prec y \iff \forall i: f_i(x) \le f_i(y) \ \wedge \ \exists j: f_j(x) < f_j(y)$$

El conjunto de Pareto P* contiene las soluciones no dominadas por ninguna otra, y su imagen en el espacio de objetivos es el **frente de Pareto**. Ningún punto del frente es mejor que los demás en todos los criterios; cada uno representa un compromiso distinto. Las funciones de escalarización lineal Σ w_i f_i sólo encuentran soluciones en partes convexas del frente, por lo que fallan cuando el frente es cóncavo o discontinuo. La escalarización de Tchebycheff evita esa limitación:

$$g^{te}(x \mid \lambda, z^*) = \max_i \lambda_i \cdot |f_i(x) - z_i^*|$$

donde λ es un vector de pesos y z* el punto ideal. Para comparar la calidad de un conjunto de soluciones A se usan indicadores. El **hipervolumen** mide el volumen del espacio de objetivos dominado por A y acotado por un punto de referencia r; es un indicador estrictamente compatible con la dominancia de Pareto:

$$HV(A; r) = \Lambda( \cup_\{a \in A\} [a, r] )$$

La **distancia generacional invertida** (IGD) mide qué tan bien cubre A al frente de referencia R, y requiere conocer el frente exacto:

$$\mathrm{IGD}(A, R) = (1/|R|) \cdot \Sigma_\{z \in R\} \min_\{a \in A\} \|z - a\|$$

Los MOEA se clasifican en dos familias. Los basados en dominancia, como **NSGA-II** (Deb et al., 2002), ordenan la población por frentes no dominados y conservan diversidad mediante la distancia de aglomeración (crowding). Los basados en descomposición, como **MOEA/D** (Zhang y Li, 2007), convierten el problema en subproblemas escalares con pesos distintos y los resuelven de forma cooperativa con sus vecinos. Ambos buscan aproximar el frente completo en una sola ejecución.

## 3. Desarrollo de la actividad

### 3.1 Problema, objetivos y codificación

Se usa el conjunto Breast Cancer Wisconsin de scikit-learn (569 muestras, 30 variables, clasificación binaria) y un perceptrón multicapa (MLP) con normalización previa. Cada solución es un vector de seis genes enteros que se decodifican en hiper parámetros:

$$g = (L, u_1, u_2, \eta, \alpha, b) \text{ con } L \in \{1, 2\}, u_1, u_2 \in \{8, 16, 32, 64\}, \eta \in \{10^{-4}, 10^{-3}, 10^{-2}, 10^{-1}\}, \alpha \in \{10^{-5}, 10^{-4}, 10^{-3}, 10^{-2}\}, b \in \{32, 64, 256\}$$

Cuando L = 1, $u_2$ no interviene y se fija en un valor canónico para evitar duplicados. El espacio de decisión tiene así **960 configuraciones distintas**. Los tres objetivos son:

- **$f_1$ = 1 − exactitud**, medida con validación cruzada estratificada de 3 pliegues (semilla fija). Mide el error de generalización.
- **$f_2$ = costo de entrenamiento** en MFLOPs, estimado con la expresión analítica 6 · p · n_train · épocas, donde p es el número de parámetros, n_train = 379 y épocas = 60. Se usa una estimación analítica y no el tiempo de reloj para que el resultado sea reproducible.
- **$f_3$ = número de parámetros** del modelo, contado con la misma convención que scikit-learn y verificado en las pruebas automatizadas.

### 3.2 Espacio exhaustivo y frente de Pareto exacto

Como el espacio tiene 960 configuraciones, todas se entrenaron y evaluaron una vez. Esa tabla completa sirve como base de verdad: el frente exacto se calcula a partir de ella y los algoritmos consultan la misma tabla, con lo que cada consulta equivale a entrenar el modelo (una prueba automatizada verifica esa equivalencia). Entre las 960 configuraciones hay 13 genotipos no dominados, pero solo **4 vectores de objetivos distintos**: en las configuraciones del frente, las cuatro variantes de α producen los mismos objetivos.

En el resto del espacio **α** sí altera la exactitud en 115 de 240 grupos, pero esas configuraciones quedan dominadas. La tabla 1 presenta el frente exacto. Este hallazgo importa para la evaluación: un método puede encontrar un mismo punto del frente con genotipos distintos, así que las métricas deben contar vectores de objetivos y no genotipos.

**Tabla 1.** Frente de Pareto exacto: los cuatro vectores de objetivos distintos (α indistinto en el rango probado).

| Capas ocultas | η (tasa) | Lote | Exactitud | Error $f_1$ | MFLOPs $f_2$ | Parámetros $f_3$ |
|---|---|---|---|---|---|---|
| 16 | 0.01 | 256 | 98.24 % | 1.76 % | 70.0 | 513 |
| 8-16 | 0.001 | 32 | 98.07 % | 1.93 % | 55.8 | 409 |
| 8-8 | 0.001 | 32 | 97.89 % | 2.11 % | 44.9 | 329 |
| 8 | 0.01 | 256 | 97.72 % | 2.28 % | 35.1 | 257 |

El frente tiene 4 vectores distintos, de 13 genotipos no dominados. El hipervolumen exacto con r = (1.1, 1.1, 1.1) normalizado es 1.3305.

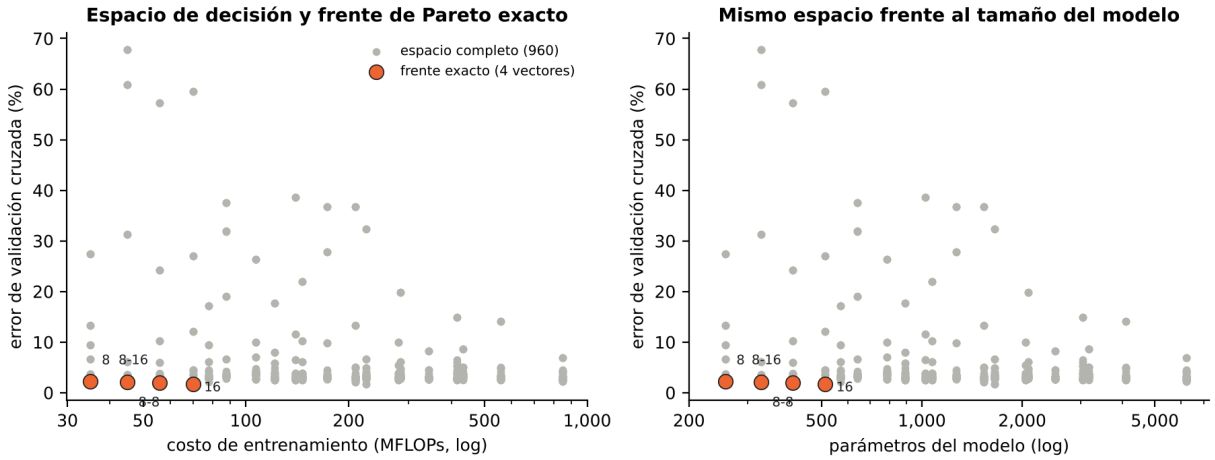



**Figura 1.** Error frente a costo de entrenamiento (izquierda) y frente al número de parámetros (derecha). En gris, las 960 configuraciones; en naranja, el frente exacto.

### 3.3 Algoritmos y protocolo experimental

Se compararon tres métodos con el mismo presupuesto de evaluaciones. Cada evaluación cuenta aunque repita un genotipo, lo que es conservador para los métodos evolutivos. Los presupuestos fueron de 100, 200 y 300 evaluaciones, es decir, entre 10 % y 31 % del espacio. Se usaron 30 semillas emparejadas por presupuesto.

- **NSGA-II:** población de 30 individuos, selección por torneo binario con criterio de rango y crowding, cruce uniforme con probabilidad 0.9, mutación por reinicio de cada gen con probabilidad 1/6 y reemplazo μ + λ con elitismo.
- **MOEA/D:** descomposición de Tchebycheff con H = 6 divisiones, 28 subproblemas, vecindario de tamaño 5 y actualización de hasta 2 vecinos por hijo; mismos operadores de variación.
- **Búsqueda aleatoria:** muestreo uniforme de genotipos con el mismo número de evaluaciones.

Todas las medidas se calcularon sobre las soluciones evaluadas, normalizadas con los valores mínimos y máximos del espacio completo. El hipervolumen usa r = 1.1 y el IGD usa el frente exacto de cuatro vectores. Para comparar los métodos se aplicó la prueba de Wilcoxon emparejada por semilla, con corrección de Holm y tamaño de efecto A12.

## 4. Resultados

### 4.1 Calidad de las aproximaciones

La tabla 2 resume la mediana del hipervolumen y del IGD, y el número medio de vectores del frente exacto encontrados (de 4). Con los tres presupuestos, el hipervolumen apenas cambia entre métodos: todos llegan a valores entre 1.3301 y 1.3305, frente a 1.3305 del frente exacto. Los 4 puntos ocupan casi todo el volumen de referencia, así que el hipervolumen es poco sensible en este problema. Por eso se reporta también el número de vectores recuperados, que es más discriminante.

**Tabla 2.** Mediana del hipervolumen (HV) e IGD, y número medio de vectores del frente recuperados (de 4), por presupuesto y algoritmo.

| Presupuesto | Algoritmo | HV (mediana) | IGD (mediana) | Vectores (de 4) |
|---|---|---|---|---|
| 100 | NSGA-II | 1.3301 | 0.0105 | 1.73 |
| 100 | MOEA/D | 1.3301 | 0.0109 | 1.40 |
| 100 | Aleatoria | 1.3303 | 0.0105 | 1.87 |
| 200 | NSGA-II | 1.3303 | 0.0105 | 2.43 |
| 200 | MOEA/D | 1.3303 | 0.0105 | 2.30 |
| 200 | Aleatoria | 1.3303 | 0.0062 | 2.40 |
| 300 | NSGA-II | 1.3303 | 0.0105 | 2.57 |
| 300 | MOEA/D | 1.3303 | 0.0105 | 2.43 |
| 300 | Aleatoria | 1.3305 | 0.0043 | 2.73 |

A 300 evaluaciones, la búsqueda aleatoria recupera en promedio 2.73 de los 4 vectores, NSGA-II 2.57 y MOEA/D 2.43. A 100 evaluaciones, NSGA-II recupera 1.73 y MOEA/D 1.40. En IGD, la aleatoria tiene la mediana más baja a 200 y 300 evaluaciones; a 300, MOEA/D es significativamente peor que ella (Holm p = 0.015). La diferencia de NSGA-II frente a la aleatoria no resulta significativa tras la corrección (p de Holm = 0.081). Entre NSGA-II y MOEA/D no hay diferencias significativas.

**Tabla 3.** IGD a 300 evaluaciones: medianas, p de Wilcoxon emparejado, p ajustada por Holm y tamaño de efecto A12 (menor es mejor).

| Presupuesto | Comparación | Medianas (a / b) | p | p de Holm |
|---|---|---|---|---|
| 300 | NSGA-II vs MOEA/D | 0.0105 / 0.0105 | 0.4259 | 0.7872 |
| 300 | NSGA-II vs Aleatoria | 0.0105 / 0.0043 | 0.0203 | 0.0813 |
| 300 | MOEA/D vs Aleatoria | 0.0105 / 0.0043 | 0.0025 | 0.0153 |

Las comparaciones a 100 y 200 evaluaciones están en el archivo de estadística del repositorio.

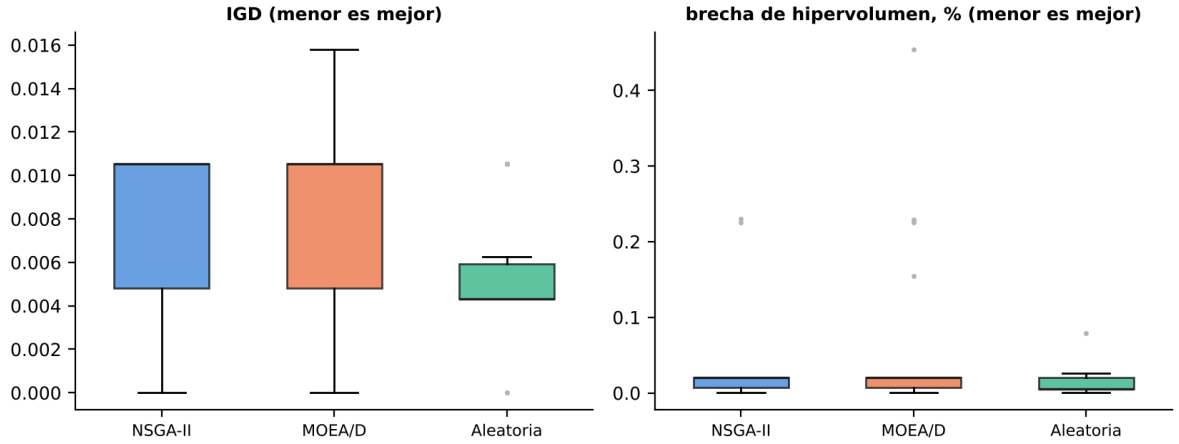



**Figura 4.** Distribución del IGD y de la brecha de hipervolumen a 300 evaluaciones (30 semillas). La brecha se mide frente al hipervolumen del frente exacto.

## 4.2 Qué puntos del frente encuentra cada método

El resultado clave del estudio es que los métodos fallan en puntos distintos del frente. La figura 2 muestra cuántos vectores se recuperan a lo largo de la búsqueda, y la figura 3 la frecuencia con que cada punto aparece en 30 semillas con 300 evaluaciones.

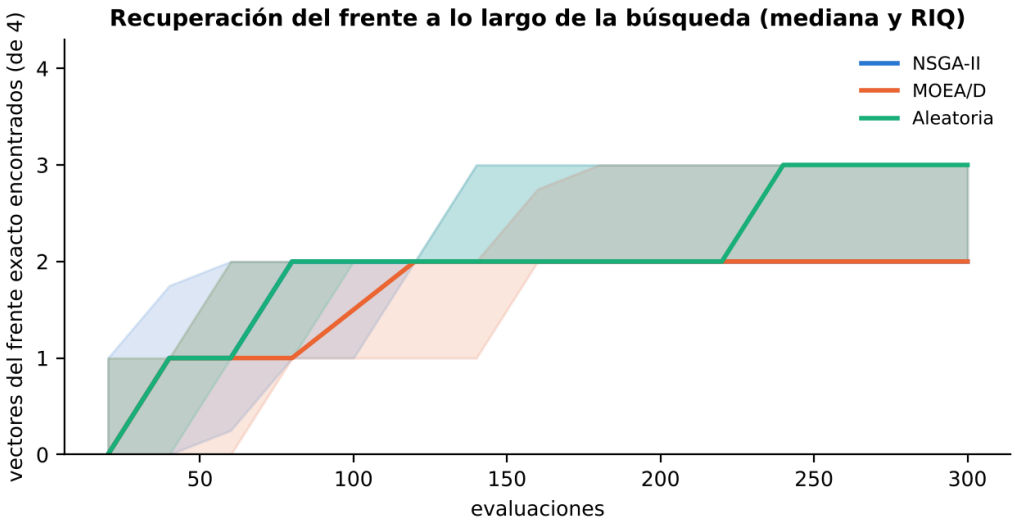



**Figura 2.** Vectores del frente exacto encontrados en función de las evaluaciones (mediana y rango intercuartílico, 30 semillas, presupuesto 300).

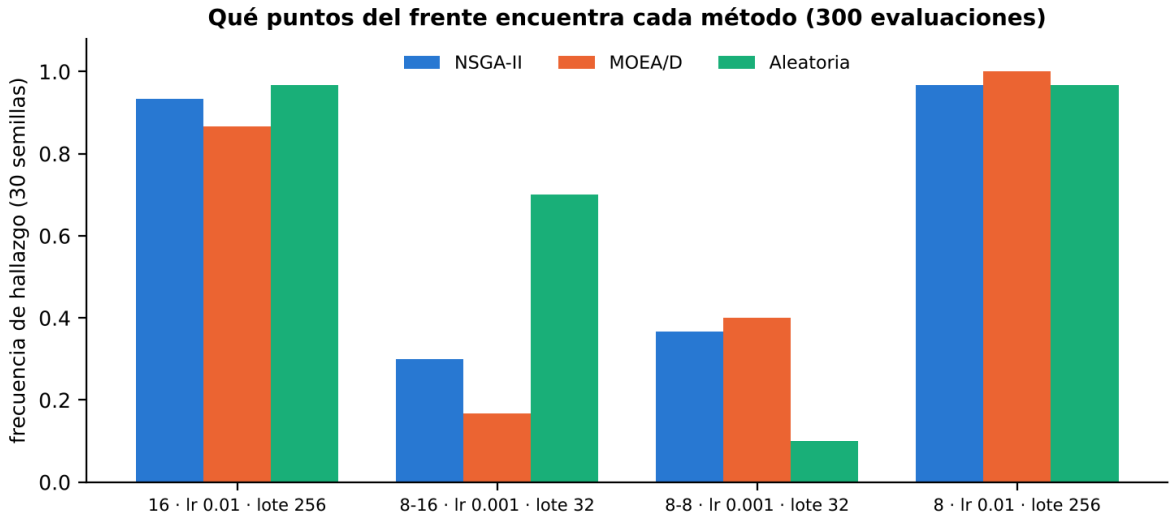



**Figura 3.** Frecuencia de hallazgo de cada punto del frente exacto con 300 evaluaciones (30 semillas).

Los dos puntos de alto rendimiento (16 unidades y 8 unidades, ambos con tasa 0.01 y lote 256) se encuentran con frecuencia alta, de 0.87 a 1.00. Los dos puntos intermedios requieren tasa de aprendizaje 0.001 y lote 32. NSGA-II los encuentra con frecuencias de 0.30 y 0.37, MOEA/D con 0.17 y 0.40, y la búsqueda aleatoria con 0.70 y 0.10. Una explicación plausible, no verificada directamente en este estudio, es que esas combinaciones intermedias son poco frecuentes en la población inicial y que, con sólo unas 10 generaciones, los operadores no alcanzan a consolidarlas. El muestreo uniforme, en cambio, las encuentra con más facilidad en el caso de 8-16.

### 4.3 Solución recomendada

Para elegir un punto del frente se usó el criterio del punto de compromiso: la solución del frente exacto más cercana al punto ideal (0, 0, 0) en el espacio normalizado. La solución elegida tiene 8 unidades ocultas, tasa de aprendizaje 0.01, lote 256, exactitud de 97.72 %, costo de 35.1 MFLOPs y 257 parámetros. Frente al punto de 16 unidades, de mayor exactitud (98.24 %), reduce a la mitad el costo y el tamaño del modelo a cambio de 0.52 puntos de exactitud. La elección depende del criterio de decisión: si la exactitud prevalece, sería el punto de 16 unidades.

## 5. Conclusiones

El ajuste de hiper parámetros tiene un frente de Pareto con pocos compromisos distintos en este problema: cuatro vectores de objetivos, a pesar de 960 configuraciones. Conocer el frente exacto permitió medir con precisión qué encuentra cada método. Con presupuestos establecidos dentro del margen de 10 % a 31 % del espacio, la búsqueda aleatoria es competitiva e incluso superior en la recuperación de puntos y en el IGD. Esto no contradice la teoría de los MOEA, porque el espacio es pequeño y los algoritmos disponen de pocas generaciones. Esto se puede observar en las gráficas e imágenes anexadas a este documento.

Los tres métodos encuentran de forma consistente los puntos de alto rendimiento. Los puntos intermedios son los que separan a los métodos: ninguno de los dos MOEA los encuentra de forma consistente, y la búsqueda aleatoria encuentra mejor el de 8-16. El hipervolumen, con r = 1.1, es poco sensible en este problema porque los cuatro puntos cubren casi todo el volumen de referencia. Para comparar algoritmos conviene combinarlo con indicadores de cobertura y de distancia, identificar las diferencias de rendimiento de cada uno permitirá comparar las coberturas en contextos diferenciados. Finalmente, la solución recomendada, de 8 unidades, tasa 0.01 y lote 256, ofrece 97.72 % de exactitud con 35 MFLOPs y 257 parámetros. La decisión final depende de la prioridad entre exactitud y costo. La decisión debe contemplar los elementos prioritarios disminuyendo el costo excesivo de los recursos finitos con los que se cuentan.

## 6. Futuras aplicaciones

- **Espacios grandes y continuos.** Con hiper parámetros continuos o con más capas y variables, el espacio no puede evaluarse por completo y los MOEA sí son la herramienta adecuada. Ahí conviene repetir la comparación contra la aleatoria con presupuestos mayores.
- **Modelos sustitutos.** Usar un modelo de regresión para predecir la exactitud y el costo, y evaluar con el modelo real solo las soluciones prometedoras, reduciendo el costo de entrenamiento.
- **Diseño de arquitecturas.** Incorporar decisiones estructurales (tipo de capa, conexiones residuales, normalización) y restricciones de latencia o memoria de dispositivos de borde.
- **Indicadores y decisores.** Estudiar el impacto de los indicadores (hipervolumen con distintos puntos de referencia, IGD+) y de la preferencia del decisor en la elección final.
- **Aprendizaje automático responsable.** Añadir objetivos de equidad entre grupos y de robustez, para obtener compromisos que consideren también criterios sociales y de confiabilidad.

## 7. Referencias

Deb, K., Pratap, A., Agarwal, S. y Meyarivan, T. (2002). A fast and elitist multiobjective genetic algorithm: NSGA-II. IEEE Transactions on Evolutionary Computation, 6(2), 182–197.

Deb, K. (2000). An efficient constraint handling method for genetic algorithms. Computer Methods in Applied Mechanics and Engineering, 186, 311–338.

Zhang, Q. y Li, H. (2007). MOEA/D: a multiobjective evolutionary algorithm based on decomposition. IEEE Transactions on Evolutionary Computation, 11(6), 712–731.

Zitzler, E. y Thiele, L. (1999). Multiobjective evolutionary algorithms: a comparative case study and the strength Pareto approach. IEEE Transactions on Evolutionary Computation, 3(4), 257–271.

Coello Coello, C. A., Lamont, G. B. y Van Veldhuizen, D. A. (2007). Evolutionary Algorithms for Solving Multi-Objective Problems (2.ª ed.). Springer.

Pedregosa, F. et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

Demšar, J. (2006). Statistical comparisons of classifiers over multiple data sets. Journal of Machine Learning Research, 7, 1–30.

Vargha, A. y Delaney, H. D. (2000). A critique and improvement of the CL common language effect size statistics. Journal of Educational and Behavioral Statistics, 25(2), 101–132.