UNIVERSIDAD POLITÉCNICA METROPOLITANA DE HIDALGO

Maestría en Inteligencia Artificial

Algoritmos genéticos en ingeniería médica, social y de trayectorias clínicas: tres escenarios de aplicación

Materia: Algoritmos Evolutivos

Alumna	Jessica Melani Romero Lora
Matrícula	25322116
Catedrático	Dr. Jaime Aguilar Ortiz
Asignatura	Algoritmos Evolutivos
Periodo	Septiembre–diciembre de 2026
Fecha de entrega	21 de octubre de 2026

Código fuente:

https://github.com/jessicaromero-ctrl/Evolutive-Algorithms/tree/main/Actividades%20Previas/previa07

1. Introducción

Muchas decisiones de ingeniería en salud se formulan como la búsqueda de una configuración que maximiza un criterio de calidad: qué combinación de indicadores anticipa mejor un diagnóstico, cómo asignar un programa preventivo entre comunidades sin dejar a un grupo sistemáticamente atrás, o cómo parametrizar la comparación entre una trayectoria clínica real y una vía guía. En los tres casos el espacio de soluciones es grande, no siempre es derivable y la función objetivo no es lineal ni diferenciable. Los algoritmos evolutivos son una familia de métodos de búsqueda que no requieren gradientes y que operan sobre poblaciones de candidatos [1][2][13].

Este reporte aplica un mismo motor de algoritmo genético (AG) a tres escenarios de ingeniería: medicina (fusión de puntuaciones de riesgo clínico), grupos sociales (asignación equitativa de un programa preventivo) y trayectorias médicas (calibración de un alineamiento de secuencias clínicas). El objetivo es mostrar qué elementos son comunes a los tres problemas, cuáles dependen del dominio y qué aporta el algoritmo frente a alternativas sencillas. Los datos son sintéticos y se generan con supuestos explícitos; los resultados describen el comportamiento de los métodos bajo esos supuestos y no constituyen evidencia clínica.

2. Referentes previos

En medicina, el aprendizaje automático se ha consolidado como herramienta de apoyo diagnóstico y de pronóstico, con revisiones que describen tanto su potencial como sus exigencias de validación [9]. La calidad de una puntuación de riesgo en problemas con clases poco frecuentes se evalúa mejor con la curva precisión–exhaustividad que con la curva ROC [5][11]. La combinación de varias puntuaciones mediante pesos optimizados es una práctica común, y los algoritmos evolutivos se han empleado para esa tarea por su capacidad de explorar espacios no convexos [3][13].

En problemas sociales, distintos trabajos han documentado que un criterio aparentemente neutro puede producir daños desiguales entre grupos; un caso emblemático es la asignación de cuidados a partir de costos históricos, que subestimó la necesidad de pacientes de un grupo racial [7]. Para formalizar la equidad se han propuesto criterios como la igualdad de oportunidades, que exige tasas de detección similares entre grupos [8][10]. El escenario 2 incorpora esa idea como un término de penalización explícito.

En trayectorias clínicas, la minería de procesos permite contrastar registros de eventos con modelos de referencia, y su aplicación en salud se ha revisado de forma sistemática [6][14]. El alineamiento global de secuencias, formulado para comparar cadenas biológicas, es un instrumento directo para medir la conformidad de una trayectoria con una vía guía [4]. El escenario 3 calibra los parámetros de ese alineamiento con un AG, en lugar de fijarlos por criterio experto.

3. Fundamentos matemáticos

Los tres escenarios son casos particulares del problema de optimización de la ecuación (1). Lo que cambia entre ellos es el dominio Θ, que determina la codificación, y la función F, que determina el paisaje de aptitud.

$$\theta^* = \operatorname{argmax}_{\theta \in \Theta} F(\theta) \quad (1)$$

La precisión media (AP, por sus siglas en inglés) resume la curva precisión–exhaustividad. Si los puntos de corte se ordenan de forma decreciente, con P_n la precisión y R_n la exhaustividad en el n-ésimo punto, se define:

$$AP = \sum_n (R_n - R_{(n-1)}) \cdot P_n \quad (2)$$

En el escenario 1, K puntuaciones normalizadas z_k se combinan linealmente con pesos que pertenecen al símplex Δ. La proyección de un vector no negativo u sobre Δ es $w_k = u_k / \sum_j u_j$:

$$s_w(x) = \sum_{k=1..K} w_k z_k(x), \quad w \in \Delta = \{w \in [0,1]^K : \sum_k w_k = 1\} \quad (3)$$

La codificación real BLX-α, usada en los escenarios 1 y 3, genera un hijo h a partir de los padres a y b con mín = min(a, b), máx = max(a, b) e intervalo I = máx − mín, muestreando $h \sim U[\text{mín} - \alpha I, \text{máx} + \alpha I]$ [3]. La mutación gaussiana acotada aplica, a cada gen j, $x'_j = \text{clip}(x_j + \delta_j \cdot \sigma \cdot (u_j - l_j), l_j, u_j)$ con $\delta_j \sim N(0,1)$ y probabilidad 1/d.

El escenario 2 usa codificación binaria $s \in \{0,1\}^Z$, donde $s_i = 1$ indica que la zona i recibe el programa. Sea N_i la necesidad esperada de la zona i, e_g la eficiencia de alcance del grupo g(i) y $b_i = N_i \cdot e_{g(i)}$.

La función objetivo es:

$$F(s; \lambda) = \sum_i s_i b_i / \sum_i N_i - \lambda \cdot (\max_g c_g - \min_g c_g) - \mu \cdot \left|\sum_i s_i - K\right|, \quad c_g = \sum_{i \in g} s_i b_i / \sum_{i \in g} N_i \quad (4)$$

El primer término es la cobertura total, el segundo penaliza la brecha de cobertura entre grupos con peso $\lambda \geq 0$ y el tercero impone el tamaño del programa mediante la penalización μ. Para Z = 20 y K = 6, el espacio factible tiene C(20, 6) = 38 760 elementos, lo que permite calcular el óptimo exacto por enumeración.

El escenario 3 usa el alineamiento global de Needleman–Wunsch [4] sobre una trayectoria T de longitud L y una vía guía R de longitud M, con parámetros $m > 0$ (coincidencia), $x < 0$ (sustitución) y $g < 0$ (hueco):

$$F(i,j) = \max\{ F(i-1,j-1) + s(T_i, R_j), F(i-1,j) + g, F(i,j-1) + g \}, \quad F(i,0) = i \cdot g, \quad F(0,j) = j \cdot g \quad (5)$$

Relación entre los elementos

Dos propiedades conectan las ecuaciones. Primera: la precisión media de la ecuación (2) depende solo del orden de las puntuaciones, por lo que $AP(y, c \cdot s) = AP(y, s)$ para todo $c > 0$ y para cualquier transformación estrictamente creciente. De aquí se sigue que la normalización del símplex en la ecuación (3) elimina una redundancia de escala sin cambiar el criterio. Segunda: en la ecuación (5), multiplicar (m, x, g) por $c > 0$ multiplica

todas las sumas de caminos por c, así que el alineamiento óptimo y el orden de las puntuaciones no cambian. El espacio efectivo del escenario 3 tiene, por tanto, dos grados de libertad, los cocientes x/m y g/m, y no tres. En el escenario 2, la función (4) es lineal a trozos en s, y el término de brecha introduce aristas que pueden atrapar a un método de búsqueda local.

4. Método común

Los tres escenarios usan el mismo núcleo de AG (archivo ga_comun.py) con los parámetros de la tabla 1. La selección es por torneo binario, el reemplazo es elitista con dos individuos y cada ejecución consume 1 940 evaluaciones de aptitud. Cada escenario se ejecuta con cinco semillas (11, 23, 37, 53 y 71). Como control, la búsqueda aleatoria usa exactamente el mismo número de evaluaciones, de modo que cualquier diferencia no se debe a un mayor presupuesto.

Tabla 1. Parámetros comunes del algoritmo genético

Parámetro	Valor	Parámetro	Valor
Población N	40	Cruce (probabilidad)	0.9
Generaciones	50	α de BLX	0.3
Elitismo	2	Desviación σ (mutación)	0.05
Torneo	2	Evaluaciones por ejecución	1 940

Tamaño de la población y generaciones definidos en ga_comun.py; el presupuesto de evaluaciones coincide con el de la búsqueda aleatoria.

5. Escenario 1: fusión de puntuaciones de riesgo clínico

Se simula una cohorte de 4 000 pacientes con seis covariables clínicas correlacionadas. El riesgo latente z es una combinación lineal de las covariables, y la presencia del evento sigue una distribución de Bernoulli con probabilidad logística de z. Cinco modelos observan z con ruido de desviación 0.5, 0.9, 1.5, 2.2 y 0.7, respectivamente. La prevalencia resultante es de 12.2 %. Las puntuaciones se estandarizan con parámetros de entrenamiento y el AG determina los pesos de la ecuación (3) maximizando la AP en la mitad del entrenamiento.

Tabla 2. Desempeño en prueba, escenario 1 (cinco semillas)

Método	AP en prueba (media ± d.e.)	ROC-AUC en prueba
Algoritmo genético	0.7737 ± 0.0308	0.9522
Búsqueda aleatoria	0.7727 ± 0.0304	0.9521
Pesos uniformes	0.7413 ± 0.0290	0.9453
Mejor modelo individual	0.7503 ± 0.0304	0.9452
Oráculo (z verdadero)	0.8054 ± 0.0246	0.9592

El oráculo usa el riesgo latente sin ruido y establece una cota superior de referencia.

El AG supera a los pesos uniformes en +0.0325 de AP en promedio y a la mejor señal individual en +0.0235, con signo positivo en las cinco semillas en ambos casos. Frente a la búsqueda aleatoria la diferencia media es de +0.0011 y su signo cambia entre semillas. En este escenario, por tanto, el AG no aporta una ventaja medible sobre el muestreo aleatorio con el mismo presupuesto: el paisaje de aptitud es suave en un símplex de cinco dimensiones, y 1 940 evaluaciones bastan para localizar una región de buen desempeño.

Los pesos aprendidos asignan en todas las semillas entre 0.75 y 0.83 de la masa a los modelos A y E, los dos de menor ruido, y el modelo D recibe peso casi nulo. La figura 1 muestra la convergencia, la dispersión en prueba y los pesos por semilla.

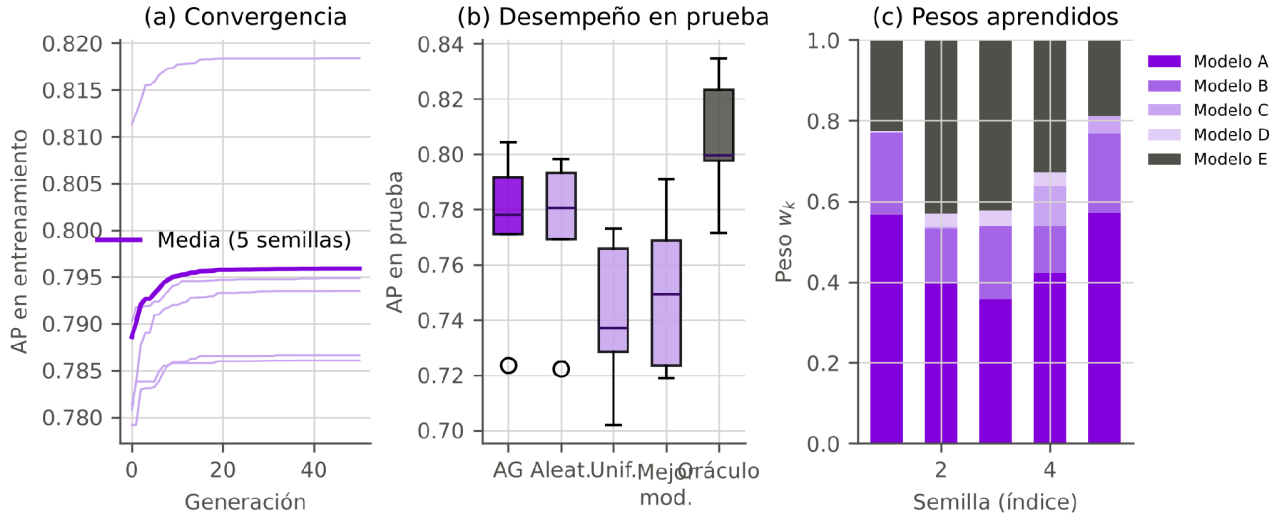


Figura 1. (a) Convergencia del AG en entrenamiento; (b) AP en prueba por método; (c) pesos aprendidos por semilla (escenario 1).

La diferencia entre el AG y el oráculo, de 0.0316 en promedio, mide el costo de no observar z directamente. Esta brecha no proviene del algoritmo, sino del ruido de los modelos, y muestra que la fusión recupera una parte del riesgo latente pero no toda.

6. Escenario 2: asignación de un programa preventivo entre grupos sociales

Se consideran 20 zonas, cada una asignada a uno de tres grupos (A, B y C) con necesidades y eficiencias de alcance distintas: el grupo A tiene eficiencia 0.80, el B 0.60 y el C 0.40. El programa debe asignarse a exactamente K = 6 zonas. Los datos son valores esperados de una población hipotética, no observaciones. El AG usa codificación binaria de 20 bits con la ecuación (4) y la penalización μ = 1. Para cada λ se compara con el óptimo exacto y con la estrategia voraz, que elige las seis zonas de mayor beneficio b_i sin considerar equidad.

Tabla 3. Compromiso entre cobertura y equidad, escenario 2

λ	F exacta	Cobertura total	Brecha	AG = óptimo	Peor F_AG − F*
0.0	0.2903	0.2903	0.3336	3 / 5	-0.0058

λ	F exacta	Cobertura total	Brecha	AG = óptimo	Peor F_AG − F*
0.25	0.2713	0.2754	0.0164	1 / 5	-0.0073
0.5	0.2672	0.2754	0.0164	0 / 5	-0.0076
1.0	0.2590	0.2754	0.0164	2 / 5	-0.0677
2.0	0.2479	0.2573	0.0047	1 / 5	-0.0887

«AG = óptimo» cuenta las semillas en que el AG alcanza el óptimo exacto. «Peor F_AG − F» es la diferencia más negativa entre el AG y el óptimo.*

La estrategia voraz obtiene la mayor cobertura total (0.2903), pero con una brecha de 0.3336: el grupo A recibe una cobertura de 0.479, frente a 0.146 en el grupo B y 0.169 en el C. Con λ = 1, el óptimo exacto selecciona las zonas 3, 4, 5, 8, 11, 14; la cobertura total baja a 0.2754, es decir, un 5.1 % menos, y la brecha se reduce a 0.0164. Ese es el costo de equidad en este caso: una pérdida moderada de cobertura total a cambio de una distribución casi uniforme entre grupos (figura 2b).

El AG encuentra el óptimo exacto en 7 de las 25 ejecuciones (tabla 3). Cuando no lo alcanza, su solución factible es peor, con una diferencia máxima de -0.089 en el peor caso. El término de brecha crea una superficie con aristas que el muestreo por torneo explora con dificultad. Aun así, la búsqueda aleatoria con el mismo presupuesto produce soluciones muy inferiores (para λ = 1, aptitudes entre 0.15 y 0.24, contra un óptimo de 0.259). La figura 2a muestra la frontera de compromiso del óptimo exacto para los cinco valores de λ; los valores λ = 0.25, 0.5 y 1 producen la misma solución, por lo que la frontera tiene solo tres puntos distintos.

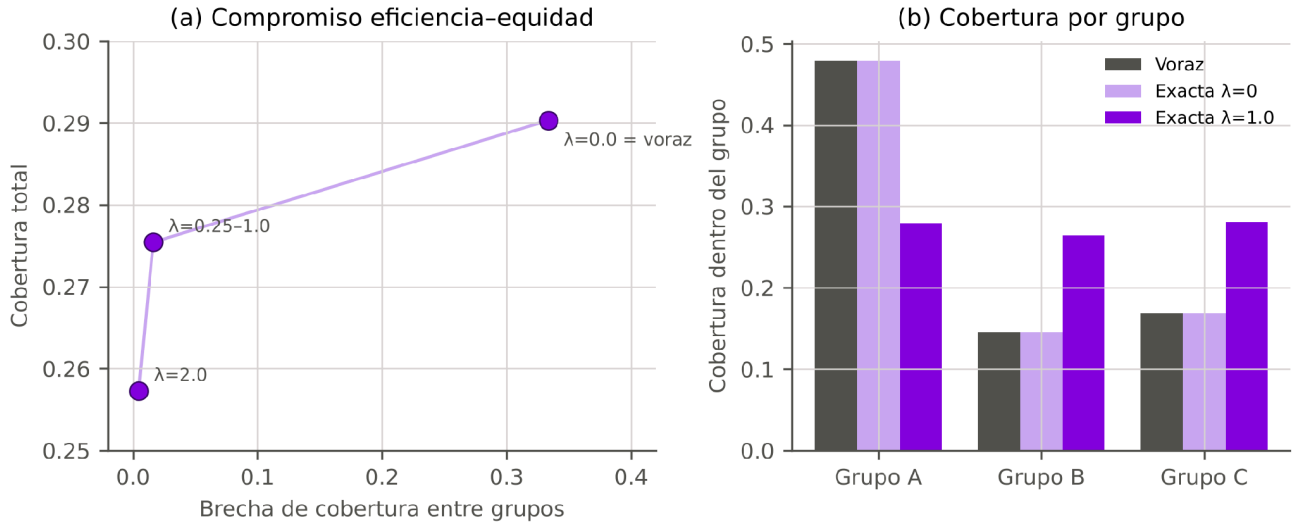


Figura 2. (a) Frontera de compromiso eficiencia–equidad del óptimo exacto; (b) cobertura por grupo para la voraz y para el óptimo exacto con λ = 0 y λ = 1 (escenario 2).

7. Escenario 3: calibración del alineamiento de trayectorias clínicas

Se generan 800 trayectorias de longitud 8 sobre un alfabeto de ocho eventos clínicos (A a H), con una prevalencia de desviación del 25 %. La vía guía es la secuencia A→H. Las trayectorias conformes sustituyen un evento de la guía con probabilidad 0.06 y repiten

eventos con probabilidad 0.04; las desviadas lo hacen con probabilidades 0.25 y 0.20. La puntuación de desviación es −F(T) de la ecuación (5). El AG calibra (m, x, g) en el dominio [0.5, 3] × [−3, −0.1]² para maximizar la AP en entrenamiento, y se compara con los valores por defecto (1, −1, −1) y con búsqueda aleatoria.

Tabla 4. Desempeño en prueba, escenario 3 (cinco semillas)

Método	AP en prueba (media ± d.e.)	ROC-AUC	Dif. AG − método	p (Wilcoxon)
Algoritmo genético	0.8140 ± 0.0254	0.9133	—	—
Búsqueda aleatoria	0.8082 ± 0.0345	0.9134	+0.0058	0.438
Parámetros por defecto	0.8009 ± 0.0223	0.9140	+0.0131	0.062

La diferencia pareada se calcula por semilla. Con cinco pares, el valor mínimo posible de p para la prueba bilateral de Wilcoxon es 0.0625.

El AG mejora la AP respecto a los valores por defecto en las cinco semillas, con una diferencia media de +0.0131 (rango de +0.0076 a +0.0174). La ROC-AUC no cambia, 0.9133 frente a 0.9140. Esta combinación es esperable: la AP da más peso a la precisión en la parte alta del ranking, donde se concentran las alertas, mientras que la ROC resume el orden global. Los parámetros aprendidos difieren entre semillas: x/m varía entre -4.79 y -0.73, y g/m entre -3.63 y -0.81. Según la invariancia de escala de la sección 3, solo estos cocientes importan para el orden; que distintas razones produzcan AP casi idénticas indica una meseta de soluciones equivalentes. La figura 3 muestra el paisaje de aptitud en el plano (x, g) con m = 1.5, la convergencia y la separación de puntuaciones en prueba.

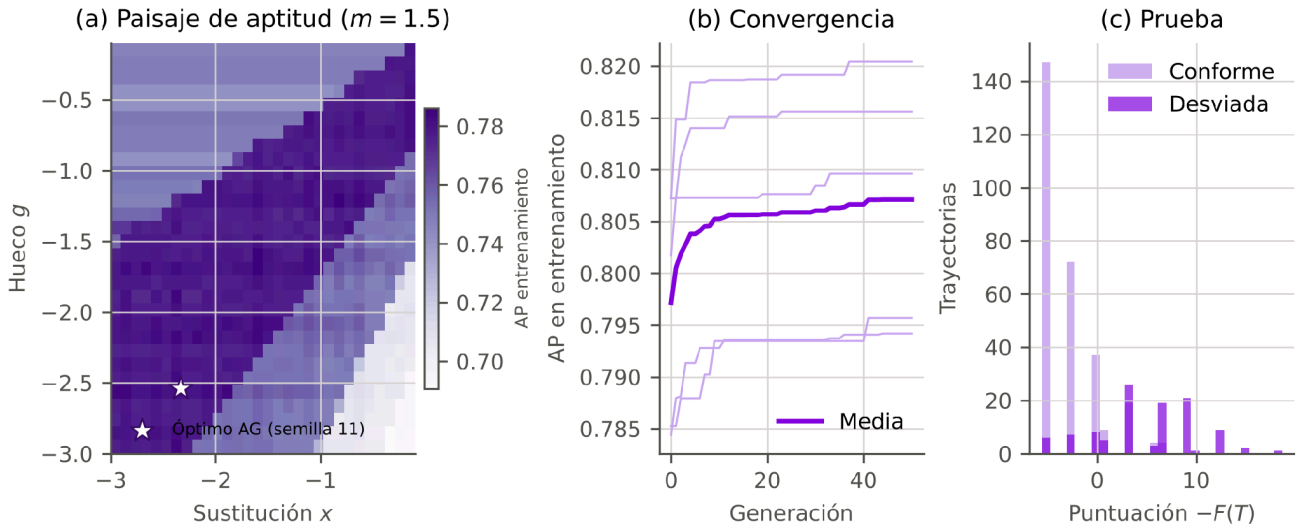


Figura 3. (a) Paisaje de aptitud (AP en entrenamiento) en el plano (x, g) con m = 1.5; (b) convergencia del AG; (c) distribución de puntuaciones en prueba para la semilla 11.

El paisaje muestra una banda diagonal de valores altos. Su forma indica que la discriminación depende de la razón entre el costo de sustitución y el costo de hueco, y no de sus valores absolutos. Por eso el AG converge a regiones distintas con desempeño similar. La separación en prueba es moderada: las trayectorias desviadas tienden a

puntuaciones más altas (la puntuación es $-F(T)$), pero con solapamiento considerable, consistente con una ROC-AUC de alrededor de 0.91.

8. Discusión

Los tres escenarios comparten una estructura: un espacio de decisión, una función objetivo y un criterio de comparación. Los resultados sugieren que la contribución principal de la metodología está en la formulación de la función objetivo. El AG resuelve bien los problemas en los que el criterio está bien definido, pero en los escenarios 1 y 3 la búsqueda aleatoria con el mismo presupuesto obtiene resultados equivalentes. La ventaja del AG aparece con más claridad en el escenario 2, donde el criterio combina términos no lineales y el espacio binario es discreto; aun así, el AG no siempre alcanza el óptimo exacto.

En el escenario 2, el resultado tiene una lectura social directa: maximizar la cobertura total produce una cobertura de 0.48 en el grupo A y de 0.15 y 0.17 en los grupos B y C. Un criterio de equidad explícito cambia la asignación a costa de una pérdida moderada de cobertura total. La decisión sobre cuánta equidad incorporar no es técnica: es un juicio de política que el modelo solo hace explícito.

En el escenario 3, la invariancia de escala implica que la calibración opera sobre dos grados de libertad. Esto reduce el costo de la búsqueda, pero también significa que la mejora de AP (+0.0131 en promedio) es pequeña frente a la variabilidad entre semillas de los datos. Conviene tratarla como evidencia direccional y no como una ganancia establecida.

Las limitaciones son importantes. Los datos son sintéticos y sus supuestos determinan los resultados; cinco semillas son una muestra pequeña y la prueba de Wilcoxon tiene poca potencia con cinco pares; las comparaciones entre métodos se hacen en un solo conjunto de condiciones; y el escenario 2 usa valores esperados, de modo que no incorpora incertidumbre sobre la necesidad real. Ninguno de los modelos debe usarse para decisiones clínicas o de asignación de recursos sin validación con datos reales, auditoría de equidad y revisión por personal especializado.

9. Conclusiones

Un mismo motor de algoritmo genético puede aplicarse a problemas de medicina, de grupos sociales y de trayectorias clínicas. Las ecuaciones (2) a (5) muestran que la métrica de evaluación y la invariancia de escala determinan qué se optimiza y cuántos grados de libertad efectivos tiene el problema. En los escenarios 1 y 3, el AG iguala a la búsqueda aleatoria y supera a las alternativas por defecto o uniformes. En el escenario 2, el AG se aproxima al óptimo exacto y supera ampliamente a la búsqueda aleatoria. La recomendación práctica es formular bien el criterio de equidad y validarlo antes de confiar en la optimización.

Referencias

[1] Holland, J. H. (1975). Adaptation in Natural and Artificial Systems. University of Michigan Press.

[2] Goldberg, D. E. (1989). Genetic Algorithms in Search, Optimization, and Machine Learning. Addison-Wesley.

[3] Eshelman, L. J., & Schaffer, J. D. (1993). Real-coded genetic algorithms and interval-schemata. En Foundations of Genetic Algorithms, 2, 187–202.

[4] Needleman, S. B., & Wunsch, C. D. (1970). A general method applicable to the search for similarities in the amino acid sequence of two proteins. Journal of Molecular Biology, 48(3), 443–453.

[5] Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. PLoS ONE, 10(3), e0118432.

[6] Rojas, E., Munoz-Gama, J., Sepúlveda, M., & Capurro, D. (2016). Process mining in healthcare: A literature review. Journal of Biomedical Informatics, 61, 224–236.

[7] Obermeyer, Z., Powers, B., Vogeli, C., & Mullainathan, S. (2019). Dissecting racial bias in an algorithm used to manage the health of populations. Science, 366(6464), 447–453.

[8] Hardt, M., Price, E., & Srebro, N. (2016). Equality of opportunity in supervised learning. Advances in Neural Information Processing Systems, 29.

[9] Rajkomar, A., Dean, J., & Kohane, I. (2019). Machine learning in medicine. New England Journal of Medicine, 380(14), 1347–1358.

[10] Barocas, S., & Selbst, A. D. (2016). Big data's disparate impact. California Law Review, 104(3), 671–732.

[11] Davis, J., & Goadrich, M. (2006). The relationship between precision-recall and ROC curves. Proceedings of the 23rd International Conference on Machine Learning, 233–240.

[12] Demšar, J. (2006). Statistical comparisons of classifiers over multiple data sets. Journal of Machine Learning Research, 7, 1–30.

[13] Eiben, A. E., & Smith, J. E. (2015). Introduction to Evolutionary Computing (2.ª ed.). Springer.

[14] van der Aalst, W. M. P. (2016). Process Mining: Data Science in Action (2.ª ed.). Springer.

Anexo. Código y reproducción

Archivo	Contenido
ga_comun.py	Núcleo del AG: codificación real (BLX-α) y binaria; búsqueda aleatoria de control
esc1_medicina.py	Escenario 1: cohorte sintética, fusión con pesos en el símplex, figura 1
esc2_grupos_sociales.py	Escenario 2: objetivo con equidad, óptimo exacto, voraz, figura 2

Archivo	Contenido
esc3_trayectorias.py	Escenario 3: alineamiento de Needleman–Wunsch, paisaje, figura 3
docx_1utils.py	Utilidades de formato y renderizado de las gráficas
docx_utils.py	Utilidades de formato, estilo y renderizado del documento.